



BÀI THUYẾT TRÌNH KDHL

Khoa học dữ liệu (Trường Đại học Kinh tế Thành phố Hồ Chí Minh)



messages.pdf_cover_qr_code_label

BÀI THUYẾT TRÌNH

NGHIÊN CỨU VÀ ỨNG DỤNG PHÂN LỚP DỮ LIỆU ĐỂ DỰ ĐOÁN MỨC LƯƠNG NGƯỜI LAO ĐỘNG

Nhóm thực hiện: NHÓM 6

CHƯƠNG 1: GIỚI THIỆU

1. Lý do chọn đề tài

Với sự phổ biến hiện nay, khoa học dữ liệu (data science) đang chứng tỏ là một con đường sự nghiệp ngày càng phát triển. Các data scientist (nhà khoa học dữ liệu) đang rất cần thiết trên toàn thế giới với những vai trò khác nhau ở các công ty khác nhau. Chuyên gia của chuyên ngành này thường được coi là thành viên thiết yếu của nhóm. Những cái nhìn sâu sắc, am hiểu tường tận của họ giúp công ty nắm được cả ưu điểm và khuyết điểm của mình, sau đó cung cấp dịch vụ tốt hơn và tối ưu hơn cho khách hàng của mình.

Với sự phát triển không ngừng nên mức độ quan tâm đến con đường sự nghiệp này là rất cao, và một trong những vấn đề chính mà nhiều người muốn biết đó là mức lương của một data scientist.

Hiện nay, công nghệ hiện đại dần phát triển mạnh mẽ hơn bao giờ hết, các dữ liệu dần đóng vai trò quan trọng trong quá trình ra quyết định và định hướng phát triển cho doanh nghiệp thì công việc của data scientist cũng trở nên quan trọng không kém.

Vì vậy, một data scientist thường có mức thu nhập rơi vào khoảng **13.000.000 – 25.000.000 đồng/tháng**. Đây là một mức lương khá cao đối với mặt bằng chung hiện nay, và tùy theo kinh nghiệm chuyên môn, kỹ năng và năng lực mà mức lương của data scientist sẽ có sự thay đổi.

Chúng tôi đã thực hiện khảo sát để hiểu rõ hơn về công cụ nào mà nhà phân tích dữ liệu và các nhà khoa học dữ liệu sử dụng và mối tương quan của những công cụ đó với tiền lương. Không phải tất cả những người trả lời mô tả vai trò chính của họ là nhà khoa học dữ liệu/nhà phân tích dữ liệu, nhưng hầu hết tất cả những người được hỏi đều được tiếp xúc với phân tích dữ liệu. Tương tự, trong khi chỉ hơn một nửa số người được hỏi tự mô tả mình là người có kỹ thuật dẫn đầu, hầu hết tất cả đều báo cáo rằng một phần vai trò của họ bao gồm công nghệ- nhiệm vụ chính (tức là 10–20% trách nhiệm của họ bao gồm phân tích dữ liệu) ysis hoặc phát triển phần mềm).

2. Mục tiêu nghiên cứu

Các yếu tố ảnh hưởng đến mức lương của họ, như kinh nghiệm, vị trí địa lý, ngành công nghiệp và trình độ học vấn. Nghiên cứu này có thể giúp cho các nhà quản lý tuyển dụng hiểu rõ hơn về mức lương của các nhà khoa học dữ liệu và đưa ra các quyết định phù hợp.

3. Đối tượng phạm vi nghiên cứu

Đối tượng nghiên cứu trong bài là các nhà nghiên cứu khoa học dữ liệu ở các năm kinh nghiệm, vị trí làm việc,.. khác nhau.

Phạm vi nghiên cứu sẽ tập trung vào việc nghiên cứu và phân loại các nhóm nhà khoa học dữ liệu, tiến hành tìm hiểu các yếu tố quan trọng như năm kinh nghiệm, lương, vị trí làm việc và các đặc điểm khác của họ.

4. Nghiên cứu 6 bước

Tiến hành vận dụng những lý thuyết đã được đưa ra vào các phương pháp nghiên cứu thực tiễn. Tuy nhiên, quy trình 6 bước này không phải cứng nhắc bởi các số thứ tự của quy trình mà có nhiều giai đoạn được quay lại.

Yếu tố quan trọng của nghiên cứu khai thác dữ liệu là phải biết được nghiên cứu để làm gì. Trong bài tiểu luận này, nhận dạng mục đích nghiên cứu các mức lương từ đó sẽ giúp cho các nhà quản lý tuyển dụng hiểu rõ hơn về mức lương của các nhà khoa học dữ liệu và đưa ra các quyết định phù hợp.

- Sau khi mục tiêu nghiên cứu và kế hoạch dự án được thiết lập, đội ngũ nhân viên tiến hành thu thập dữ liệu ban đầu, mô tả, khảo sát và kiểm tra chất lượng dữ liệu. Trong quá trình thu thập dữ liệu cần lưu ý các biến được chọn cho những dữ liệu liên quan phải độc lập với nhau, thông tin không được trùng lặp.

- Khi nguồn dữ liệu được xác định, dữ liệu cần được chọn lọc, làm sạch, gán vào các mẫu mong muốn và định dạng bằng cách sử dụng các phương pháp thống kê, phân tích dữ liệu, hồi quy... để dự báo mô hình kinh tế thông qua các chỉ số với sự hỗ trợ của phần mềm Orange và Excel. Qua đó, dữ liệu được biến đổi sao cho thuận tiện nhất trong việc sử dụng khi khai thác dữ liệu.

- Xây dựng mô hình dữ liệu là lúc phần mềm khai thác dữ liệu Orange được sử dụng để tạo ra kết quả. Ở đây chủ yếu sử dụng kỹ thuật phân lớp với chủ đích đưa ra kết quả đánh giá phân lớp sai và năng lực tự động dự báo. Một khi hiểu hơn về dữ liệu, nhiều mô hình chi tiết, hợp lý cho dữ liệu có thể được sử dụng.

- Các kết quả mô hình cần được đánh giá trong bối cảnh mục tiêu nghiên cứu được thiết lập ở giai đoạn đầu tiên. Để diễn giải một cách hợp lý mô hình tri thức, điều quan trọng là phải chọn được công cụ trực quan thích hợp như biểu đồ tròn, biểu đồ phân phối tần số, biểu đồ hộp, đồ thị phân tán... Thông thường, diễn dịch bằng đồ thị càng đơn giản thì người sử dụng càng dễ hiểu.

- Thông qua việc tri thức được khám phá trong các giai đoạn trước đó của quy trình, các mô hình có thể được áp dụng cho hoạt động kinh doanh trong nhiều mục đích, bao gồm dự báo hoặc nhận dạng các tình hình quan trọng. Những mô hình này cần được giám sát với các thay đổi trong điều kiện vận hành doanh nghiệp bởi vì hành vi khách hàng thay đổi theo thời gian và dữ liệu có thể đã bị thay đổi. Do đó, điều quan trọng là thông tin khách hàng phải được giám sát trong thời gian triển khai.

5. Ý nghĩa



Việc nghiên cứu về Data science salaries có thể giúp các doanh nghiệp, các nhà tuyển dụng cũng như các Data science hiểu rõ hơn về mức lương của mình để có thể đưa ra những quyết định đúng đắn. Từ đó tránh những trường hợp mức lương nhận được không đúng với thực lực của mình, và sự chênh lệch mức lương giữa các doanh nghiệp.

CHƯƠNG 2: TÌM HIỂU DỮ LIỆU

1. Thu thập dữ liệu

Nguồn dữ liệu: Bộ dữ liệu được thu thập và tạo ra bởi một sinh viên đã tốt nghiệp người Ấn Độ, được đăng tải trên trang web Kaggle. Tập dữ liệu bao gồm thông tin dữ liệu thô chứa 3755 hàng dữ liệu (người lao động) và 11 cột (đặc tính).

Phân loại người lao động: Đào tạo dữ liệu về thông tin của người làm việc cùng với các thông tin như: trình độ năng lực, loại việc làm, vai trò công việc, mức lương, mức thu nhập, nơi ở, vị trí công ty, quy mô công ty...

# work_year Year of work	▲ experience_level Level of Experience	▲ employment_type Type of Employment	▲ job_title Designation	# salary Salary in Amount
	SE 67% MI 21% Other (434) 12%	FT 99% PT 0% Other (20) 1%	Data Engineer 28% Data Scientist 22% Other (1875) 50%	
▲ salary_currency Currency	# salary_in_usd Salary in dollars	▲ employee_reside... Residence	# remote_ratio Ratio of Working remotely	▲ company_location Company Location
USD 86% EUR 6% Other (295) 8%		US 80% GB 4% Other (584) 16%		US 81% GB 5% Other (543) 14%

2. Mô tả dữ liệu

Đây là tập dữ liệu mô tả các đặc điểm xoay quanh thu nhập của nhân viên của công ty

Loại dữ liệu: Dữ liệu thu thập bao gồm cả dữ liệu số (numerical) và dữ liệu danh mục (categorical). Mỗi dòng tương ứng với một đặc điểm của việc làm của người lao động. Dữ liệu số bao gồm mức lương, năm làm việc, lương quy đổi qua USD. Dữ liệu chữ bao gồm trình độ năng lực, loại việc làm, chức danh, nơi ở, nơi làm việc, quy mô công ty.

Kích thước tập dữ liệu: Tập dữ liệu bao gồm khoảng 3755 dòng và 11 cột. Mỗi dòng tương ứng với những đặc điểm và thu nhập của một người lao động cụ thể.

Cấu trúc dữ liệu: Dữ liệu được lưu trữ dưới dạng bảng, với mỗi hàng chứa thông tin về một giao dịch hoặc tương tác và mỗi cột đại diện cho một biến cụ thể như: Mỗi dòng tương ứng với trình độ, năm làm việc, loại việc làm, chức danh, lương, đơn vị tiền lương, thu nhập tính theo đồng USD, quê quán, tỉ lệ từ xa, nơi làm việc, quy mô công ty

Nguồn dữ liệu: Dữ liệu này được thu thập từ Kaggle ghi lại thông tin về các việc làm và thu nhập của người lao động trong năm 2023.

Dataset Characteristic (Đặc điểm của tập dữ liệu): Đa biến

Số lượng mẫu:

Tranning data: 3755

Số lượng thuộc tính; bao gồm 10 thuộc tính

Attribute Chacteristics (đặc điểm thuộc tính): categorical

Missing value (giá trị bị thiếu): bằng không

Các thuộc tính:

Tên cột	Miêu tả đặc tính
work_year	Năm được trả lương
experience_level	Trình độ năng lực làm việc
employment_type	Loại công việc theo vai trò
job_title	Vai trò trong công việc
salary	Tổng lương được trả
salary_currency	Đồng ngoại tệ lương được chi trả
Salary_in_usd	Tiền lương theo đồng USD
employee_residence	Quê quán của người lao động
remote_ratio	Khối lượng công việc làm từ xa
company_location	Quốc gia của cơ sở làm việc
company_size	Số lượng nhân viên làm việc cho công ty trong năm

3. Phương pháp thu thập dữ liệu

Phương pháp thu thập dữ liệu: Giải thích cách đã thu thập dữ liệu. Dữ liệu được thu thập tự động từ hệ thống theo một lịch trình định kỳ. Quá trình thu thập dữ liệu được tự động hóa để đảm bảo tính đồng nhất và liên tục của dữ liệu.

Kiểm tra chất lượng dữ liệu: Đề cập đến bất kỳ vấn đề nào liên quan đến chất lượng dữ liệu, như giá trị thiếu, giá trị trùng lặp, hoặc các vấn đề khác đã phát hiện và xử lý.

Tạo Data Dictionary: Đưa ra một danh sách hoặc bảng mô tả các biến trong tập dữ liệu, bao gồm tên biến, loại dữ liệu, ý nghĩa, và các thông tin khác cần thiết để người đọc hiểu dữ liệu.


Mô tả các biến chính: Đặc biệt mô tả các biến mà công ty dự định sử dụng trong phân loại người lao động, bao gồm mô tả về ý nghĩa của từng biến trong ngữ cảnh của dự án.

Biểu đồ và trực quan hóa: gồm biểu đồ hoặc hình ảnh minh họa cho dữ liệu được thể hiện dưới đây:


Năm làm việc:



Trình độ năng lực:



Loại công việc:



Vai trò công việc:



Lương:

salary

Salary in Amount



Valid	3755	100%
Mismatched	0	0%
Missing	0	0%
Mean	191k	
Std. Deviation	672k	
Quantiles	6000	Min
	100.0k	25%
	138k	50%
	180k	75%
	30.4m	Max

Ngoại tệ lương:

A salary_currency

Currency




Valid	3755	100%
Mismatched	0	0%
Missing	0	0%
Unique	20	
Most Common	USD	86%

Lương tính theo USD:

salary_in_usd

Salary in dollars



Valid	3755	100%
Mismatched	0	0%
Missing	0	0%
Mean	138k	
Std. Deviation	63k	
Quantiles	5132	Min
	95.0k	25%
	135k	50%
	175k	75%
	450k	Max

Quốc quán:

A employee_residence

Residence




Valid	3755	100%
Mismatched	0	0%
Missing	0	0%
Unique	78	
Most Common	US	80%

Tỉ lệ làm việc từ xa:

remote_ratio

Ratio of Working remotely



Valid	3755	100%
Mismatched	0	0%
Missing	0	0%
Mean	46.3	
Std. Deviation	48.6	
Quantiles		
	0	Min
	0	25%
	0	50%
	100	75%
	100	Max

Nơi làm việc:

A company_location

Company Location


US	81%
GB	5%
Other (543)	14%

Valid	3755	100%
Mismatched	0	0%
Missing	0	0%
Unique	72	
Most Common	US	81%

CHƯƠNG 3: TIỀN XỬ LÝ DỮ LIỆU


1. Tích hợp dữ liệu

Tải file dữ liệu excel của dự án và đưa vào Orange.



Dựa vào phần mềm Orange, ta có được màn hình tùy chọn cho bộ dữ liệu cần tiền xử lý. Bộ dữ liệu hiện tại có 3755 quan sát (**instances**), 11 tính năng, không có tỷ lệ dữ liệu bị thiếu (**missing value**), không biến mục tiêu (**no target variable**), đồng thời không có biến meta (**biến biến đổi**).

Mục tiêu của dự án là dự đoán mức độ kinh nghiệm theo từng cấp độ (EN, EX, MI, SE) nên sẽ thay đổi đặc trưng của **Experience_level** (mức độ kinh nghiệm) thành biến mục tiêu (**target**).




2. Làm sạch dữ liệu


Đây là một bước vô cùng quan trọng để chúng ta có thể tiến hành phân tích một bộ dữ liệu trên Orange.

2.1 Loại bỏ dữ liệu không cần thiết

Hầu hết các bộ dữ liệu đều có từ ít nhất 1 danh mục dữ liệu không cần thiết trong quá trình phân tích. Từ bộ dữ liệu gốc, ta có thể nhận thấy feature **salaries** và feature **salaries_currency** không gây ảnh hưởng đến kết quả phân lớp, không tác động đến quá trình phân tích dữ liệu, nên chúng ta sẽ loại bỏ đặc trưng **salaries** và **salaries_currency** tổng file dữ liệu bằng cách **ignored features** trong lệnh **Select columns** trên phần mềm Orange.



Mường tượng (Visualize) dữ liệu để xem phân bố dữ liệu của từng thuộc tính từ đó tìm xem có các giá trị nào của thuộc tính nào bị nhiễu và đưa ra cách xử lý có nên loại dòng đó ra không. (Distribution Widget).



Xem lại dữ liệu đã xử lý (Data Table widget)

Data Table (1) - Orange

Info
3755 instances (no missing data)
8 features
Target with 4 values
No meta attributes.

Variables
☒ Show variable labels (if present)
☐ Visualize numeric values
☒ Color by instance classes

Selection
☒ Select full rows


Restore Original Order

Send Automatically

	experience_level	work_year	employment_type	job_title	salary_in_usd	employee_residence	remote_ratio	company_location	company_size
1	SE	2023	FT	Principal Data S...	85847	ES	100	ES	L
2	MI	2023	CT	ML Engineer	30000	US	100	US	S
3	MI	2023	CT	ML Engineer	25500	US	100	US	S
4	SE	2023	FT	Data Scientist	175000	CA	100	CA	M
5	SE	2023	FT	Data Scientist	120000	CA	100	CA	M
6	SE	2023	FT	Applied Scientist	222200	US	0	US	L
7	SE	2023	FT	Applied Scientist	136000	US	0	US	L
8	SE	2023	FT	Data Scientist	219000	CA	0	CA	M
9	SE	2023	FT	Data Scientist	141000	CA	0	CA	M
10	SE	2023	FT	Data Scientist	147100	US	0	US	M
11	SE	2023	FT	Data Scientist	90700	US	0	US	M
12	SE	2023	FT	Data Analyst	130000	US	100	US	M
13	SE	2023	FT	Data Analyst	100000	US	100	US	M
14	EN	2023	FT	Applied Scientist	213660	US	0	US	L
15	EN	2023	FT	Applied Scientist	130760	US	0	US	L
16	SE	2023	FT	Data Modeler	147100	US	0	US	M
17	SE	2023	FT	Data Modeler	90700	US	0	US	M
18	SE	2023	FT	Data Scientist	170000	US	0	US	M
19	SE	2023	FT	Data Scientist	150000	US	0	US	M
20	MI	2023	FT	Data Analyst	150000	US	100	US	M
21	MI	2023	FT	Data Analyst	110000	US	100	US	M
22	SE	2023	FT	Research Engin...	275000	DE	0	DE	M
23	SE	2023	FT	Research Engin...	174000	DE	0	DE	M
24	SE	2023	FT	Analytics Engin...	230000	GB	100	GB	M
25	SE	2023	FT	Analytics Engin...	143200	GB	100	GB	M
26	SE	2023	FT	Business Intellig...	225000	US	0	US	M
27	SE	2023	FT	Business Intellig...	156400	US	0	US	M
28	SE	2023	FT	Machine Learn...	200000	US	0	US	M
29	SE	2023	FT	Machine Learn...	130000	US	0	US	M
30	SE	2023	CT	Data Scientist	00000	CA	0	CA	M

3755 | 3755 | 3755

Lưu dữ liệu đã xử lý Save data với tên mới ds_salaries (đã xử lý)



Mở file ds_salaries (đã xử lý) (file widget)

Visualize dữ liệu để quan sát toàn bộ dữ liệu sau khi đã xử lý. (Distribution Widget)

The screenshot shows the Orange3 software interface. On the left is a widget palette with categories: Data (File, CSV File Import, Datasets, SQL Table, Data Table, Paint Data, Data Info, Rank), Transform (Edit Domain, Color, Feature Statistics, Save Data), and Visualize (Distributions, etc.). The main workspace displays the workflow diagram from the previous image. Below the diagram, the 'Data Table' widget is selected, showing a description: 'View the dataset in a spreadsheet.' The bottom status bar indicates the system temperature is 28°C and the date is 22/11/2023.


CHƯƠNG 4: XÂY DỰNG VÀ ĐÁNH GIÁ KẾT QUẢ MÔ HÌNH

1. Xây dựng mô hình:

Sau khi đã qua bước tiền xử lý dữ liệu, chúng ta được bộ dữ liệu dùng để xây dựng và kiểm định như sau:

Bộ dữ liệu dùng để xây dựng có tên là *ds_salaries* 2 bao gồm 3755 instances, có Experience level là biến mục tiêu, còn lại là biến liên quan (work year, employment type, job title, salary, employee residence,...) và 0 dữ liệu lỗi.


Hình 4.1. Mẫu dữ liệu dùng để xây dựng mô hình



The screenshot shows the Orange Data Mining interface with a 'Data Table' widget. The left sidebar contains settings for the widget, including 'Info' (3755 instances, 9 features, 4 target values), 'Variables' (Show variable labels, Visualize numeric values, Color by instance classes), and 'Selection' (Select full rows). The main table displays the following columns: experience_level, work_year, employment_type, job_title, salary, salary_currency, salary_in_usd, employee_residence, remote_ratio, and company_size. The data is sorted by experience_level, showing various roles like Principal Data Scientist, ML Engineer, Data Scientist, Applied Scientist, Data Analyst, Research Engineer, Analytics Engineer, Business Intelligence Engineer, Machine Learning Engineer, Data Strategist, and Data Engineer across different years and companies.


	experience_level	work_year	employment_type	job_title	salary	salary_currency	salary_in_usd	employee_residence	remote_ratio	company_size
1	SE	2023	FT	Principal Data S...	80000	EUR	85817	ES	100	L
2	MI	2023	CT	ML Engineer	30000	USD	30000	US	100	S
3	MI	2023	CT	ML Engineer	25500	USD	25500	US	100	S
4	SE	2023	FT	Data Scientist	175000	USD	175000	CA	100	M
5	SE	2023	FT	Data Scientist	120000	USD	120000	CA	100	M
6	SE	2023	FT	Applied Scientist	222200	USD	222200	US	0	L
7	SE	2023	FT	Applied Scientist	136000	USD	136000	US	0	L
8	SE	2023	FT	Data Scientist	219000	USD	219000	CA	0	M
9	SE	2023	FT	Data Scientist	141000	USD	141000	CA	0	M
10	SE	2023	FT	Data Scientist	147100	USD	147100	US	0	M
11	SE	2023	FT	Data Scientist	90700	USD	90700	US	0	M
12	SE	2023	FT	Data Analyst	130000	USD	130000	US	100	M
13	SE	2023	FT	Data Analyst	100000	USD	100000	US	100	M
14	FN	2023	FT	Applied Scientist	213660	USD	213660	US	0	L
15	FN	2023	FT	Applied Scientist	130760	USD	130760	US	0	L
16	SL	2023	FT	Data Modeler	147100	USD	147100	US	0	M
17	SL	2023	FT	Data Modeler	90700	USD	90700	US	0	M
18	SE	2023	FT	Data Scientist	170000	USD	170000	US	0	M
19	SE	2023	FT	Data Scientist	150000	USD	150000	US	0	M
20	MI	2023	FT	Data Analyst	150000	USD	150000	US	100	M
21	MI	2023	FT	Data Analyst	110000	USD	110000	US	100	M
22	SE	2023	FT	Research Engin...	275000	USD	275000	DE	0	M
23	SE	2023	FT	Research Engin...	174000	USD	174000	DE	0	M
24	SE	2023	FT	Analytics Engin...	230000	USD	230000	GB	100	M
25	SE	2023	FT	Analytics Engin...	143200	USD	143200	GB	100	M
26	SE	2023	FT	Business Intellig...	225000	USD	225000	US	0	M
27	SE	2023	FT	Business Intellig...	156400	USD	156400	US	0	M
28	SE	2023	FT	Machine Learni...	200000	USD	200000	US	0	M
29	SE	2023	FT	Machine Learni...	130000	USD	130000	US	0	M
30	SE	2023	FT	Data Strategist	90000	USD	90000	CA	0	M
31	SE	2023	FT	Data Strategist	72000	USD	72000	CA	0	M
32	SE	2023	FT	Data Engineer	253200	USD	253200	US	0	M
33	SE	2023	FT	Data Engineer	90700	USD	90700	US	0	M
34	SL	2023	FT	Computer Visio...	342810	USD	342810	US	0	M
35	SL	2023	FT	Computer Visio...	184590	USD	184590	US	0	M
36	MI	2023	FT	Data Engineer	162500	USD	162500	US	0	M
37	MI	2023	FT	Data Engineer	130000	USD	130000	US	0	M

Hình 4.2. Mô hình tổng quát




2. Sử dụng mô hình:

Chọn thuộc tính Experience_level là thuộc tính biến target để dự đoán.



Hình 4.3. Chọn biến target cho tập dữ liệu huấn luyện

Sử dụng các phương pháp SVM, Decision Tree, Logistic Regression (hồi quy Logistic), Neural Network để phân lớp




Hình 4.4. Mô hình phân lớp

3. Kết quả phân tích và đánh giá:

3.1. Test and Score:


Sử dụng Test and Score để so sánh, đánh giá các thuật toán nhằm lựa chọn thuật toán tốt và chính xác nhất cho việc dự đoán.




Hình 4.5. Kết quả Test and Score

3.2. Ma trận nhầm lẫn:


Kết quả phân tích dựa trên ma trận nhầm lẫn (*Confusion Matrix*)




Hình 4.6. Ma trận nhầm lẫn với phương pháp Logistic Regression



Hình 4.7. Ma trận nhầm lẫn với phương pháp Neural Network



Hình 4.8. Ma trận nhầm lẫn với phương pháp SVM



Hình 4.9. Ma trận nhầm lẫn với phương pháp Decision Tree


3.3. Đánh giá kết quả:

- Dựa trên kết quả của **Test And Score**, ta thấy Neural Network là mô hình đáng tin cậy nhất với các thông số có chênh lệch ít nhất và có diện tích AUC lớn nhất (0.776). Trong khi đó, độ tin cậy của ba mô hình còn lại kém hơn hẳn khi có diện tích phần AUC lần lượt là 0.731 (Logistic Regression), 0.764 (Decision Tree), 0.508 (SVM) thông số của những mô hình này cũng có sự chênh lệch khá cao.
- Dựa trên kết quả giữa bốn bảng **Ma Trận Nhầm Lẫn**, ta nhận ra được mô hình Neural Network có phần trăm số lượng mẫu dữ liệu được dự đoán chính xác lớn nhất, sau đó lần lượt là Decision Tree, SVM và Logistic Regression.

Do đó, mô hình Neural Network là mô hình cho kết quả tối ưu và đáng tin cậy nhất trong cả 4 mô hình được thử nghiệm.

3.4. Lựa chọn mô hình:

Thông qua những kết quả thu được và sự phân tích, ta thấy sử dụng mô hình *Neural Network* cho việc dự đoán bộ dữ liệu “Data Science Salaries 2023” là chính xác nhất.



	work_year	experience_level	employment_type	job_title	salary	salary_currency	salary_usd	employee_residence	remote_ratio	company_size
1	SE	2023	FT	Principal Data S...	80000	EUR	85847	ES		100 L
2	MI	2023	CT	ML Engineer	30000	USD	30000	US		100 S
3	MI	2023	CT	ML Engineer	25500	USD	25500	US		100 S
4	SE	2023	FT	Data Scientist	175000	USD	175000	CA		100 M
5	SE	2023	FT	Data Scientist	120000	USD	120000	CA		100 M
6	SE	2023	FT	Applied Scientist	222200	USD	222200	US		0 L
7	SE	2023	FT	Applied Scientist	136000	USD	136000	US		0 L
8	SE	2023	FT	Data Scientist	219000	USD	219000	CA		0 M
9	SE	2023	FT	Data Scientist	141000	USD	141000	CA		0 M
10	SE	2023	FT	Data Scientist	147100	USD	147100	US		0 M
11	SE	2023	FT	Data Scientist	90700	USD	90700	US		0 M
12	SE	2023	FT	Data Analyst	130000	USD	130000	US		100 M
13	SE	2023	FT	Data Analyst	100000	USD	100000	US		100 M
14	SE	2023	FT	Applied Scientist	213660	USD	213660	US		0 L
15	SE	2023	FT	Applied Scientist	130760	USD	130760	US		0 L
16	SE	2023	FT	Data Modeler	147100	USD	147100	US		0 M
17	SE	2023	FT	Data Modeler	90700	USD	90700	US		0 M
18	SE	2023	FT	Data Scientist	170000	USD	170000	US		0 M
19	SE	2023	FT	Data Scientist	150000	USD	150000	US		0 M
20	SE	2023	FT	Data Analyst	150000	USD	150000	US		100 M
21	SE	2023	FT	Data Analyst	110000	USD	110000	US		100 M
22	SE	2023	FT	Research Engin...	275000	USD	275000	DE		0 M
23	SE	2023	FT	Research Engin...	174000	USD	174000	DE		0 M
24	SE	2023	FT	Analytics Engin...	230000	USD	230000	GB		100 M
25	SE	2023	FT	Analytics Engin...	143200	USD	143200	GB		100 M
26	SE	2023	FT	Business Intellig...	225000	USD	225000	US		0 M
27	SE	2023	FT	Business Intellig...	156400	USD	156400	US		0 M
28	SE	2023	FT	Machine Learni...	200000	USD	200000	US		0 M
29	SE	2023	FT	Machine Learni...	130000	USD	130000	US		0 M
30	SE	2023	FT	Data Strategist	90000	USD	90000	CA		0 M
31	SE	2023	FT	Data Strategist	72000	USD	72000	CA		0 M
32	SE	2023	FT	Data Engineer	253200	USD	253200	US		0 M
33	SE	2023	FT	Data Engineer	90700	USD	90700	US		0 M
34	SE	2023	FT	Computer Visio...	342810	USD	342810	US		0 M
35	SE	2023	FT	Computer Visio...	184590	USD	184590	US		0 M
36	SE	2023	FT	Data Engineer	162500	USD	162500	US		0 M
37	SE	2023	FT	Data Engineer	130000	USD	130000	US		0 M

Hình 4.10. Bảng kết quả dự đoán của mô hình Neural Network

Nhìn vào hình 4.10, ta có thể thấy mô hình Neural Network đã dự đoán được nhân viên nào sẽ có cấp độ kinh nghiệm nào.

CHƯƠNG 5: KẾT LUẬN

1. Tổng kết

Dựa trên quá trình nghiên cứu và ứng dụng phân lớp dữ liệu để dự đoán mức lương người lao động, chúng ta đã thực hiện một số bước quan trọng để hiểu rõ và áp dụng các phương pháp phân loại trong lĩnh vực này. Sử dụng bộ dữ liệu Customer Segmentation Classification và công cụ Orange, chúng ta đã có cơ hội:

1. Tiền xử lý dữ liệu: Đã thực hiện các bước tiền xử lý dữ liệu để làm sạch và chuẩn hóa thông tin, từ việc loại bỏ dữ liệu lặp lại đến xử lý các giá trị thiếu, giúp cải thiện chất lượng dữ liệu đầu vào.

2. Phân tích đặc trưng: Sử dụng các công cụ phân tích đặc trưng trong Orange, chúng ta đã có cơ hội xác định những đặc trưng quan trọng đóng vai trò quan trọng trong việc dự đoán mức lương người lao động.

3. Xây dựng mô hình phân lớp: Áp dụng các thuật toán phân loại trong Orange để xây dựng mô hình. Các kỹ thuật như Decision Trees, Support Vector Machines, hoặc Neural Networks đã giúp chúng ta tạo ra mô hình dự đoán có hiệu suất khả quan.

4. Đánh giá mô hình: Thực hiện các bước đánh giá mô hình để đảm bảo tính chính xác và độ tin cậy của dự đoán. Các thước đo như độ chính xác, độ nhạy, độ chính xác toàn cầu đã cung cấp cái nhìn chi tiết về hiệu suất của mô hình.

5. Ứng dụng kết quả: Kết luận đề tài bằng việc thảo luận về ứng dụng thực tế của mô hình phân loại trong việc dự đoán mức lương người lao động. Các kết quả có thể hỗ trợ quyết định tuyển dụng, định giá lao động, hay thậm chí đề xuất chính sách về lương thưởng.

Cuối cùng, đề tài đã đưa ra cái nhìn toàn diện về quá trình nghiên cứu và ứng dụng phân lớp dữ liệu để giải quyết vấn đề dự đoán mức lương, đồng thời mở rộng các tri thức và kỹ năng trong lĩnh vực Data Science và Machine Learning.

2. Hạn chế

Vì đây chỉ là dữ liệu trên Kaggle được thu thập vào năm 2023 nên theo thời gian có thể những thông tin đó sẽ bị sai lệch và lỗi thời. Dữ liệu về lương có thể được thu thập từ cá nhân hoặc cộng đồng nên sẽ đôi lúc thiếu sót và thiếu chính xác thông tin. Bên cạnh đó mức lương còn có thể bị chênh lệch nếu đề cập tới các ngành công nghiệp khác nhau.

Do những liệu trên Kaggle còn gặp một chút vấn đề về số liệu nên việc đưa ra dự đoán sẽ có sai sót và ảnh hưởng rất lớn đến việc dự đoán về lương người lao động dẫn đến việc gây khó khăn cho nhà tuyển dụng khi đánh giá về môi trường lao động dựa trên mức lương và nhân sự.