



Pham Minh Nguyen Hoc May UD

quản trị học (Đại học Nguyễn Tất Thành)



messages.pdf_cover_qr_code_label

TRƯỜNG ĐẠI HỌC NGUYỄN TẤT THÀNH
KHOA CÔNG NGHỆ THÔNG TIN



TIỂU LUẬN HỌC MÁY VÀ ỨNG DỤNG

**HỆ THỐNG DỰ ĐOÁN LƯƠNG VÀ NHU CẦU KỸ
NĂNG TRÊN THỊ TRƯỜNG VIỆC LÀM**

Giảng viên hướng dẫn: ThS. CHÂU GIA HÂN

Sinh viên thực hiện: PHẠM MINH NGUYỄN

MSSV: 2200007986

Khoá: 2022-2026

Ngành/ chuyên ngành: KHOA HỌC DỮ LIỆU

Tp HCM, tháng 9 năm 2025

TRƯỜNG ĐẠI HỌC NGUYỄN TẤT THÀNH
KHOA CÔNG NGHỆ THÔNG TIN



TIỂU LUẬN HỌC MÁY VÀ ỨNG DỤNG

**HỆ THỐNG DỰ ĐOÁN LƯƠNG VÀ NHU CẦU KỸ
NĂNG TRÊN THỊ TRƯỜNG VIỆC LÀM**

Giảng viên hướng dẫn: ThS. CHÂU GIA HÂN

Sinh viên thực hiện: PHẠM MINH NGUYỄN

MSSV: 2200007986

Khoá: 2022-2026

Ngành/ chuyên ngành: KHOA HỌC DỮ LIỆU

Tp HCM, tháng 9 năm 2025

LỜI MỞ ĐẦU

Trong bối cảnh thị trường việc làm ngày càng biến động và cạnh tranh khốc liệt, việc nắm bắt xu hướng lương và nhu cầu kỹ năng trở thành yếu tố then chốt giúp doanh nghiệp xây dựng chiến lược nhân sự hiệu quả, đồng thời hỗ trợ người lao động định hướng nghề nghiệp rõ ràng. Đối với nhà quản lý, phân tích chính xác dữ liệu về lương và kỹ năng không chỉ là cơ sở để hoạch định chiến lược tuyển dụng, đào tạo, mà còn góp phần hình thành chính sách đãi ngộ cạnh tranh, thu hút và giữ chân nhân tài. Với người lao động, những thông tin minh bạch và kịp thời về mức lương cũng như xu hướng kỹ năng trên thị trường sẽ mang lại nền tảng vững chắc để đưa ra quyết định nghề nghiệp và đầu tư phát triển bản thân.

Trong những năm gần đây, cùng với sự phát triển mạnh mẽ của các thuật toán học máy (Machine Learning – ML), nhiều nghiên cứu đã chứng minh hiệu quả của việc ứng dụng ML trong dự đoán lương và phân tích nhu cầu kỹ năng. ML không chỉ mang đến khả năng phân tích và dự đoán nhanh chóng, mà còn giúp phát hiện các mối quan hệ tiềm ẩn giữa kỹ năng, vị trí công việc và mức lương, từ đó nâng cao giá trị thực tiễn của các hệ thống hỗ trợ ra quyết định trong quản trị nhân sự.

Xuất phát từ thực tế này, nhóm lựa chọn đề tài **“Hệ thống dự đoán lương và nhu cầu kỹ năng trên thị trường việc làm”** với mong muốn vừa củng cố kiến thức về ứng dụng học máy trong khai thác và phân tích dữ liệu việc làm, vừa rèn luyện khả năng vận dụng các mô hình dự đoán hiện đại nhằm khám phá xu hướng quan trọng về lương và kỹ năng. Ngoài ra, việc thử nghiệm và so sánh nhiều phương pháp học máy khác nhau cũng giúp nhóm tìm ra hướng tiếp cận tối ưu, tạo tiền đề tham khảo cho những nghiên cứu và ứng dụng thực tiễn sau này.

Với tinh thần cầu thị, báo cáo này khó tránh khỏi những hạn chế nhất định. Nhóm rất mong nhận được sự góp ý từ thầy cô và bạn bè để hoàn thiện hơn, đồng thời mở ra các hướng nghiên cứu mới trong tương lai.

LỜI CẢM ƠN

Để thực hiện và hoàn thành tốt đề án này, em đã nhận được sự giúp đỡ và hướng dẫn rất tận tình của các thầy cô thuộc Khoa Công Nghệ Thông Tin – Đại Học Nguyễn Tất Thành. Em xin cảm ơn các thầy cô thuộc bộ môn chuyên ngành đã cung cấp cho em các thông tin, kiến thức vô cùng quý báu và cần thiết trong suốt thời gian quá để em có thể thực hiện và hoàn thành đề án của mình. Đặc biệt em xin chân thành cảm ơn giảng viên Châu Gia Hân người đã trực tiếp hướng dẫn em trong thời gian thực hiện đề tài này.

Cuối cùng xin chân thành cảm ơn các bạn trong ngành công nghệ thông tin đã ủng hộ, giúp đỡ, chia sẻ kiến thức, kinh nghiệm và tài liệu có được giúp chúng em trong quá trình nghiên cứu và thực hiện đề tài.

Do giới hạn về mặt thời gian và kiến thức cũng như kinh nghiệm thực tiễn tên đề tài không tránh khỏi những sai sót. Em rất mong nhận được sự thông cảm của quý thầy cô và mong đón nhận những góp ý của thầy cô và các bạn.

Em xin chân thành cảm ơn

TRƯỜNG ĐẠI HỌC NGUYỄN TẤT THÀNH
TRUNG TÂM KHẢO THÍ

KỲ THI KẾT THÚC HỌC PHẦN
HỌC KỲ 3 NĂM HỌC 2024 - 2025

PHIẾU CHẤM THI TIỂU LUẬN

Môn thi: Học máy và ứng dụng..... Lớp học phần: 22DTH4B.....

Nhóm sinh viên thực hiện :

1. Nguyễn Xuân Tiến..... Tham gia đóng góp: 100%.....

2. Phạm Minh Nguyễn..... Tham gia đóng góp: 100%.....

Ngày thi: 29/09/2025..... Phòng thi: L.....

Đề tài tiểu luận/báo cáo của sinh viên : Hệ thống dự đoán lương và nhu cầu kỹ năng trên thị trường việc làm

Phần đánh giá của giảng viên (căn cứ trên thang rubrics của môn học):

Tiêu chí (theo CDR HP)	Đánh giá của GV	Điểm tối đa	Điểm đạt được
Cấu trúc của báo cáo			
Nội dung			
- Các nội dung thành phần			
- Lập luận			
- Kết luận			
Trình bày			
TỔNG ĐIỂM			

Giảng viên chấm thi
(ký, ghi rõ họ tên)

MỤC LỤC

CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI.....	1
1.1 Tính cấp thiết của đề tài.....	1
1.2 Mô tả bài toán.....	2
1.3 Đối tượng và phạm vi nghiên cứu.....	3
1.4 Mục tiêu đề tài.....	4
CHƯƠNG 2: NGHIÊN CỨU LIÊN QUAN.....	6
2.1 Các nghiên cứu về dự đoán lương.....	6
2.2 Các nghiên cứu về phân tích mô tả công việc (JD).....	7
2.3 Các nghiên cứu về dữ liệu thị trường lao động.....	8
2.4 Điểm mới của đề tài.....	8
CHƯƠNG 3 :BỘ DỮ LIỆU.....	10
3.1 Giới thiệu và Thu thập.....	10
3.2 Quy trình khai phá (EDA - Exploratory Data Analysis).....	14
3.2.1 Thống kê mô tả.....	14
3.2.2 Phân tích thuộc tính (Numerical/Quantitative Variables).....	17
3.2.3 Phân tích biến đơn.....	27
3.2.4 Phân tích biến bội.....	31
3.2.5 Phân tích đa biến.....	35
3.3 Nhận xét chất lượng bộ dữ liệu.....	36

CHƯƠNG 4 :PHƯƠNG PHÁP ĐỀ XUẤT.....	40
4.1 Mô hình.....	40
4.1.1 Random Forest.....	40
4.1.2 LightGBM.....	42
4.1.3 CatBoost.....	45
4.2 Công nghệ sử dụng.....	47
CHƯƠNG 5: THỰC NGHIỆM.....	49
5.1 Quy trình thực nghiệm.....	49
5.1.1 Xử lý dữ liệu.....	49
5.1.2 Chuẩn bị dữ liệu cho mô hình.....	57
5.2 Độ đo đánh giá.....	58
5.2.1 Các Độ đo Đánh giá Chính.....	58
5.2.2 Độ đo chính xác khoảng.....	59
5.3 Thông số chi tiết các thuật toán.....	61
5.3.1 RandomForestRegressor.....	61
5.3.2 LGBMRegressor.....	61
5.3.3 CatBoostRegressor.....	62
5.4 Đánh giá thực nghiệm.....	62

5.4.1 Kết quả thực nghiệm.....	62
5.4.2 Nhận xét.....	63
5.4.2.1 Đánh giá tổng quan.....	63
5.4.2.2 Đánh giá theo từng độ đo.....	64
5.4.2.3 Phân tích nguyên nhân.....	65
5.4.2.4 Phương pháp Cải thiện.....	65
CHƯƠNG 6 :KẾT LUẬN.....	67
6.1 Tóm tắt đề tài.....	67
6.2 Đóng góp của đề tài.....	68
CHƯƠNG 7 :HƯỚNG PHÁT TRIỂN ĐỀ TÀI.....	69

DANH MỤC HÌNH

Hình 3.1: Thống kê mô tả dữ liệu.....	15
Hình 3.2: Thống kê mô tả tần suất dữ liệu.....	16
Hình 3.3: Tổng số giá trị thiếu.....	17
Hình 3.4: Biểu đồ phân bố Rating.....	28
Hình 3.5: Biểu đồ phân bố lương trung bình.....	29
Hình 3.6: Biểu đồ liệt kê số lượng công việc.....	30
Hình 3.7: Biểu đồ phân bố khu vực tuyển dụng.....	31
Hình 3.8: Biểu đồ phân bố giữa lương và đánh giá.....	32
Hình 3.9: Biểu đồ phân bố mức lương trung bình theo khu vực.....	33
Hình 3.10: Biểu đồ phân bố lương theo ngành nghề.....	34
Hình 3.11: Ma trận tương quan giữa các biến số.....	35
Hình 4.1: Mô hình Random forest.....	41
Hình 4.2: Mô hình LightGBM.....	43
Hình 5.1 : Trích xuất skill,exp,edu.....	53
Hình 5.2: Phân loại kỹ năng.....	54
Hình 5.3: Xử lý giá trị exp.....	55
Hình 5.4: Gán giá trị cho nhóm kỹ năng.....	56
Hình 5.5: Sử dụng LabelEncode.....	56

DANH MỤC BẢNG

Bảng 3.1: Mô tả bộ dữ liệu sử dụng.....	14
Bảng 3.2: Thống kê mô tả EDA.....	17
Bảng 3.3: Tần số size.....	20
Bảng 3.4: Tần số Revenue.....	22
Bảng 3.5: Tần số Industry.....	23
Bảng 3.6: Tần số Type of Ownership.....	24
Bảng 3.7: Tần số Sector.....	27
Bảng 3.8: Kiểu dữ liệu các cột.....	38
Bảng 3.9: Giá trị NaN.....	39

DANH MỤC CÁC KÍ HIỆU, CÁC CHỮ VIẾT TẮT

Ký hiệu	Danh mục tiếng anh	Danh mục tiếng việt
MAE	Mean Absolute Error	Độ lỗi tuyệt đối
MedAE	Median Absolute Error	Sai số tuyệt đối trung vị
RAE	Relative Absolute Error	Sai số tuyệt đối tương đối
MSE	Mean Squared Error	Sai số bình phương trung bình
RMSE	Root Mean Square Error	Căn bậc 2 của bình phương độ lỗi
R²	R-squared, Coefficient of Determination	Hệ số xác định
LSTM	Long Short-Term Memory	Bộ nhớ ngắn dài hạn
CNN	Convolutional Neural Network	Mạng Nơ-ron Tích Chập
RNN	Recurrent Neural Network	Mạng Nơ-ron Hồi quy
ARIMA	AutoRegressive Integrated Moving Average	Mô hình Trung bình trượt tích hợp tự hồi quy
SVM	Support Vector Machine	Máy vector hỗ trợ

CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI

1.1 Tính cấp thiết của đề tài

Trong thời kỳ chuyển đổi số và sự phát triển mạnh mẽ của Cách mạng Công nghiệp 4.0, dữ liệu đã nổi lên như một nguồn lực chiến lược, đóng vai trò trung tâm trong việc thúc đẩy tăng trưởng và đổi mới ở hầu hết các lĩnh vực kinh tế – xã hội. Sự bùng nổ của các ngành khoa học dữ liệu, phân tích dữ liệu, kỹ thuật dữ liệu và phân tích kinh doanh không chỉ mở ra nhiều cơ hội mới, mà còn kéo theo nhu cầu nhân lực chất lượng cao ngày càng gia tăng. Tuy nhiên, cùng với sự phát triển đó, thị trường lao động trong lĩnh vực này cũng bộc lộ nhiều thách thức cần được nghiên cứu và giải quyết.

- **Thách thức đối với người lao động:**

Đối với người lao động, việc xác định một mức lương tương xứng với trình độ, kỹ năng và kinh nghiệm cá nhân vẫn là thách thức lớn. Sự thiếu minh bạch và thiếu chuẩn hóa trong thông tin về lương khiến họ có nguy cơ nhận mức thu nhập thấp hơn giá trị thực hoặc gặp khó khăn trong quá trình thương lượng. Đồng thời, việc liên tục cập nhật và rèn luyện những kỹ năng mà thị trường ưu tiên trở thành yếu tố then chốt để duy trì lợi thế cạnh tranh và định hướng con đường nghề nghiệp lâu dài.

- **Thách thức đối với nhà tuyển dụng:**

Vì vậy, nhà tuyển dụng không chỉ đối mặt với áp lực tối ưu hóa chi phí mà còn phải xây dựng chiến lược đãi ngộ hợp lý, đảm bảo tính công bằng và minh bạch trong hệ thống lương thưởng. Đồng thời, doanh nghiệp cần thường xuyên cập nhật xu hướng thị trường lao động, ứng dụng các công cụ phân tích dữ liệu hiện đại để xác định chính xác nhu cầu kỹ năng và dự báo biến động nhân sự. Đây là cơ sở quan trọng giúp tổ chức duy trì lợi thế cạnh tranh, thu hút nhân tài và phát triển đội ngũ bền vững.

- **Thách thức từ thị trường:**

Bên cạnh đó, thị trường lao động trong lĩnh vực dữ liệu luôn biến động mạnh. Sự phát triển nhanh của công nghệ cùng với thay đổi trong nhu cầu kinh tế khiến mức lương và yêu cầu kỹ năng liên tục thay đổi. Trong hoàn cảnh này, việc thiếu vắng các công cụ hỗ trợ phân tích và cập nhật tự động trở thành rào cản, khiến cả người lao động lẫn doanh nghiệp gặp khó khăn trong việc bắt kịp và thích ứng với những xu hướng mới.

- **Tính cấp thiết của giải pháp:**

Những hạn chế nêu trên không chỉ ảnh hưởng đến cá nhân và doanh nghiệp, mà còn cản trở sự vận hành minh bạch và bền vững của thị trường lao động. Do đó, việc xây dựng một hệ thống có khả năng phân tích dữ liệu tuyển dụng, dự báo mức lương, và nhận diện các kỹ năng trọng yếu là hết sức cấp thiết. Hệ thống này sẽ mang lại lợi ích đa chiều: hỗ trợ người lao động trong việc định vị giá trị bản thân, giúp doanh nghiệp nâng cao hiệu quả tuyển dụng, đồng thời cung cấp cơ sở tham khảo hữu ích cho các đơn vị đào tạo. Trên cơ sở đó, thị trường lao động sẽ vận hành minh bạch, cân bằng và hiệu quả hơn.

Viết cho t một đoạn khác nhưng vẫn giữ nguyên nội dung

1.2 Mô tả bài toán

Đề tài tập trung vào việc xây dựng một hệ thống học máy có khả năng dự đoán mức lương cho các vị trí công việc trong lĩnh vực dữ liệu, bao gồm **Data Analyst**, **Data Scientist**, **Data Engineer** và **Business Analyst**, **Other** (các ngành về data khác nhưng chiếm số ít) , dựa trên thông tin được trích xuất từ các bản tin tuyển dụng.

Định nghĩa bài toán

Input:

Thông tin chi tiết liên quan đến một vị trí công việc, được thu thập từ các nền tảng tuyển

dụng trực tuyến (trong phạm vi nghiên cứu này, dữ liệu được khai thác từ **Glassdoor** thông qua nguồn công khai trên **Kaggle**). Các thuộc tính chính bao gồm, nhưng không giới hạn ở:

- Mô tả công việc (Job Description – JD)
- Chức danh công việc (Job Title)
- Thông tin doanh nghiệp (Tên công ty, quy mô, loại hình, lĩnh vực hoạt động, doanh thu)
- Địa điểm làm việc (Location)
- Yêu cầu kỹ năng (Skills)
- Yêu cầu kinh nghiệm (Experience)
- Yêu cầu học vấn (Education)
- Mức lương ước tính (Salary Estimate – thường được thể hiện dưới dạng khoảng giá trị)

Output:

Dự đoán mức lương tương ứng với công việc. Trong phạm vi của nghiên cứu này, bài toán được quy đổi thành một bài toán **phân loại nhị phân** với định nghĩa cụ thể như sau:

- **1**: Mức lương dự đoán nằm trong khoảng *min–max* được xác định từ dữ liệu.
- **0**: Mức lương dự đoán nằm ngoài khoảng *min–max*.

1.3 Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu

Đề tài tập trung vào việc khảo sát và phân tích các yếu tố ảnh hưởng đến mức lương trong lĩnh vực dữ liệu, với các khía cạnh cụ thể sau:

- Các yếu tố quyết định mức lương của những vị trí công việc liên quan đến dữ liệu.

- Các kỹ năng và yêu cầu công việc phổ biến, được rút trích từ các bản mô tả công việc (Job Description – JD).
- Các thuật toán học máy có khả năng ứng dụng cho bài toán dự đoán lương cũng như phân tích văn bản trong JD.
- Quy trình xử lý dữ liệu lớn, đặc biệt là dữ liệu văn bản phi cấu trúc từ mô tả công việc.

Phạm vi nghiên cứu

- **Dữ liệu:** Nghiên cứu giới hạn trong phạm vi dữ liệu tuyển dụng của bốn vị trí chính: Data Analyst, Data Scientist, Data Engineer và Business Analyst. Dữ liệu được thu thập từ Kaggle, có nguồn gốc từ Glassdoor, với phạm vi chủ yếu tại thị trường lao động Hoa Kỳ (dựa trên các thông tin về thành phố và bang xuất hiện trong tập dữ liệu).
- **Phương pháp:** Đề tài áp dụng các bước tiền xử lý dữ liệu (làm sạch, chuẩn hóa, xử lý văn bản bằng TF-IDF và/hoặc mô hình ngôn ngữ lớn – LLM), phân tích khám phá dữ liệu (Exploratory Data Analysis – EDA), và triển khai một số thuật toán học máy hiện đại như **XGBoost**, **LightGBM** và **CatBoost**.
- **Kết quả kỳ vọng:** Xây dựng được mô hình dự đoán mức lương dưới dạng **phân loại nhị phân**, đồng thời thực hiện phân tích tần suất xuất hiện của các kỹ năng để làm rõ xu hướng yêu cầu của thị trường lao động trong lĩnh vực dữ liệu.

1.4 Mục tiêu đề tài

Nghiên cứu này đặt ra mục tiêu tổng quát là phát triển một hệ thống học máy có khả năng dự đoán mức lương trong lĩnh vực dữ liệu dựa trên thông tin tuyển dụng trực tuyến. Để đạt được mục tiêu đó, đề tài hướng đến các mục tiêu cụ thể sau:

1. **Xây dựng bộ dữ liệu thống nhất:** Tiến hành thu thập và tích hợp bốn tập dữ liệu khác nhau từ Kaggle (nguồn gốc từ Glassdoor) thành một cơ sở dữ liệu chuẩn hóa, bảo đảm tính đầy đủ và nhất quán cho phân tích.
2. **Khảo sát đặc trưng dữ liệu:** Thực hiện phân tích khám phá nhằm nhận diện đặc điểm nổi bật của từng biến số, làm rõ mối liên hệ giữa các yếu tố (ví dụ: kỹ năng, kinh nghiệm, địa điểm, ngành nghề) với mức lương, đồng thời minh họa bằng các hình thức trực quan hóa dữ liệu.
3. **Hoàn thiện quy trình tiền xử lý:** Đề xuất và triển khai một chuỗi bước xử lý dữ liệu bao gồm phát hiện và xử lý giá trị khuyết, loại bỏ nhiễu, chuẩn hóa thông tin và đặc biệt là phân tích văn bản trong mô tả công việc. Việc trích xuất các yếu tố quan trọng (kỹ năng, trình độ, kinh nghiệm) sẽ được hỗ trợ bởi các phương pháp hiện đại như TF-IDF hoặc mô hình ngôn ngữ lớn (LLM) – chẳng hạn Gemini.
4. **Xây dựng và thử nghiệm mô hình:** Phát triển các mô hình dự đoán mức lương theo hướng phân loại nhị phân, đồng thời tiến hành so sánh hiệu quả giữa nhiều thuật toán khác nhau, bao gồm XGBoost, LightGBM, CatBoost và TabNet.
5. **Đánh giá và lựa chọn mô hình:** Sử dụng các chỉ số đánh giá chuẩn mực trong học máy như Accuracy, Precision, Recall và F1-score để đo lường hiệu suất, từ đó xác định mô hình có khả năng dự đoán tối ưu nhất.
6. **Phân tích xu hướng kỹ năng:** Trích xuất và thống kê tần suất xuất hiện của các kỹ năng trong dữ liệu tuyển dụng, qua đó đưa ra bức tranh khái quát về những năng lực được thị trường lao động lĩnh vực dữ liệu ưu tiên.
7. **Tổng hợp kết quả nghiên cứu:** Biên soạn một báo cáo học thuật hoàn chỉnh, bao gồm quá trình triển khai, các kết quả đạt được, đánh giá hạn chế, và định hướng cho những nghiên cứu tiếp theo.

CHƯƠNG 2: NGHIÊN CỨU LIÊN QUAN

2.1 Các nghiên cứu về dự đoán lương

Các mô hình học máy truyền thống đã được áp dụng rộng rãi trong dự đoán lương. Ví dụ, nghiên cứu “*Statistical Machine Learning Regression Models for Salary Prediction Featuring Economy-Wide Activities and Occupations*” của Matbouli và Alghamdi (2022) [15] đã thử nghiệm nhiều mô hình hồi quy, trong đó Gaussian Process Regression đạt hiệu quả vượt trội với R^2 lên đến 0.98, cao hơn đáng kể so với Linear Regression. Tương tự, nghiên cứu “*The Investigation and Prediction for Salary Trends in the Data Science Industry*” của Jiang (2024) [13] đã so sánh Random Forest, XGBoost, Neural Network và SVR, kết quả cho thấy XGBoost có ưu thế về tốc độ trong khi Neural Network và SVR lại có độ chính xác cao hơn dựa trên RMSE, MAE và MAPE.

Các thuật toán boosting như XGBoost, LightGBM, và CatBoost tiếp tục chứng minh hiệu quả. Trong nghiên cứu “*Salary Prediction Using Ensemble Learning Models*” (Deshpande & Shinde, 2023) [9], XGBoost được áp dụng để dự đoán lương kỹ sư phần mềm, mang lại kết quả chính xác và ổn định hơn so với các mô hình truyền thống.

Đối với các mô hình học sâu (Deep Learning), nghiên cứu “*Salary Prediction Model using Principal Component Analysis and Deep Neural Network Algorithm*” của Aminu và cộng sự (2023) [2] đã kết hợp PCA và DNN để phân loại mức lương, đạt độ chính xác cao hơn Decision Tree và Random Forest. Bên cạnh đó, Ji, Sun và Zhu (2025) với công trình “*Enhancing Job Salary Prediction with Disentangled Composition Effect Modeling: A Neural Prototyping Approach*” [12] đã đề xuất mô hình LGDESetNet, vừa dự đoán lương vừa giải thích được vai trò của từng kỹ năng đối với thu nhập. Gần đây, Alsheyab và cộng sự (2025) trong nghiên cứu “*Job Market Cheat Codes: Prototyping Salary Prediction and Job Grouping with Synthetic Job Listings*”

[1] đã áp dụng kết hợp hồi quy, phân loại và clustering trên dữ liệu việc làm tổng hợp, cho thấy tiềm năng của phương pháp đa tác vụ trong phân tích thị trường lao động.

2.2 Các nghiên cứu về phân tích mô tả công việc (JD)

Xử lý ngôn ngữ tự nhiên (NLP) là công cụ trọng tâm trong phân tích mô tả công việc. Các phương pháp truyền thống như TF-IDF đã được ứng dụng để trích xuất kỹ năng từ tin tuyển dụng. Ví dụ, nghiên cứu **“Automatic Extraction of Skills from Job Postings Using TF-IDF and Clustering Techniques”** (Kumar et al., 2019) cho thấy TF-IDF có thể hỗ trợ nhận diện các kỹ năng phổ biến trong dữ liệu JD [19]. Một nghiên cứu khác, **“Skill Extraction from Job Advertisements using TF-IDF Approach”** (Ahmed & Mehmood, 2020) cũng chứng minh hiệu quả nhưng đồng thời chỉ ra hạn chế trong việc nắm bắt ngữ cảnh [20].

Để khắc phục hạn chế của TF-IDF, các kỹ thuật Word Embeddings đã được áp dụng. Chẳng hạn, nghiên cứu **“Skill2Vec: A Method for Representing Skills from Job Postings”** (Roy et al., 2021) đã sử dụng Word2Vec để biểu diễn kỹ năng tiềm ẩn và phát hiện mối liên hệ giữa các kỹ năng [21]. Bổ sung cho hướng này, nghiên cứu **“Document Embeddings for Job Recommendation and Skill Extraction”** (Li & Chen, 2020) đã khai thác Doc2Vec nhằm trích xuất thông tin ngữ nghĩa sâu hơn từ JD [22].

Song song, Nhận dạng thực thể có tên (NER) đã được cải tiến nhờ các mô hình Transformer. Tiêu biểu là **“JobBERT: Pre-trained Language Model for Job Postings”** (Zhang et al., 2022), trong đó mô hình được huấn luyện đặc thù trên dữ liệu JD để tăng độ chính xác khi trích xuất kỹ năng [23]. Ngoài ra, nghiên cứu **“SKILLSPAN: A Benchmark Corpus for Skill Extraction”** (Auer et al., 2021) đã xây dựng bộ dữ liệu chuẩn hóa cho NER trong lĩnh vực kỹ năng, mở rộng khả năng so sánh và đánh giá [24].

Gần đây, các mô hình ngôn ngữ lớn (LLMs) đã mở ra hướng nghiên cứu mới. Herandi et al. (2024) với nghiên cứu **“Skill-LLM: Fine-tuning Large Language Models for Skill Extraction”** đã chứng minh LLaMA tinh chỉnh có thể vượt qua các phương pháp SOTA trong trích xuất kỹ năng từ JD [25]. Các nghiên cứu khác như **“Zero-Shot Skill Extraction with GPT Models”** (Martinez et al., 2023) cho thấy LLM có thể áp dụng trực tiếp trong bối cảnh ít dữ liệu gán nhãn [26]. Một số hướng tiếp cận kết hợp LLMs với Knowledge Graphs và các hệ thống phân loại như ESCO (European Skills, Competences, Qualifications and Occupations), ví dụ **“Integrating Knowledge Graphs with LLMs for Multilingual Skill Extraction”** (Schumacher et al., 2023), đã chứng minh tính hiệu quả trong việc chuẩn hóa và liên kết kỹ năng ở quy mô toàn cầu [27].

2.3 Các nghiên cứu về dữ liệu thị trường lao động

Nhiều báo cáo từ các tổ chức tư vấn chiến lược toàn cầu (ví dụ: McKinsey, Gartner) cũng như từ các nền tảng tuyển dụng trực tuyến (chẳng hạn LinkedIn, Glassdoor) đã thường xuyên tiến hành phân tích thị trường lao động, qua đó cung cấp cái nhìn về những kỹ năng có nhu cầu cao, sự khác biệt về mức lương giữa các khu vực địa lý và giữa các nhóm vị trí công việc. Song song với đó, một số công trình nghiên cứu học thuật tập trung vào việc khảo sát và định lượng “khoảng cách kỹ năng” (skill gaps) bằng cách đối chiếu giữa yêu cầu trong mô tả công việc và hồ sơ của ứng viên. Các kết quả này không chỉ phản ánh xu hướng tuyển dụng mà còn đóng vai trò tham chiếu quan trọng cho việc xây dựng và điều chỉnh các chương trình đào tạo, nhằm đáp ứng tốt hơn nhu cầu của thị trường lao động.

2.4 Điểm mới của đề tài

So với các công trình nghiên cứu trước, đề tài này thể hiện sự khác biệt thông qua việc tích hợp nhiều hướng tiếp cận hiện đại.

- Thứ nhất, dữ liệu được xây dựng từ nhiều nguồn và được hợp nhất thành một bộ dữ liệu tổng hợp, cho phép phân tích toàn diện hơn đối với bốn nhóm vai trò chính trong lĩnh vực dữ liệu.
- Thứ hai, đề tài thử nghiệm ứng dụng mô hình ngôn ngữ lớn (Gemini) trong giai đoạn tiền xử lý, nhằm trích xuất thông tin có cấu trúc từ mô tả công việc. Đây là một hướng tiếp cận mới, khắc phục những hạn chế của các phương pháp xử lý ngôn ngữ tự nhiên truyền thống.
- Thứ ba, nghiên cứu tiến hành so sánh hiệu quả của nhiều mô hình học máy, bao gồm các thuật toán boosting tiêu biểu như XGBoost, LightGBM và CatBoost, để xác định mô hình phù hợp nhất.

Nhờ sự kết hợp này, đề tài không chỉ kế thừa những kỹ thuật đã có mà còn mở rộng bằng việc ứng dụng các công cụ tiên tiến, đặc biệt là LLM, qua đó đưa ra một giải pháp hiệu quả và gắn với xu hướng công nghệ hiện nay.

CHƯƠNG 3 :BỘ DỮ LIỆU

3.1 Giới thiệu và Thu thập

Nguồn dữ liệu chủ đạo của nghiên cứu được khai thác từ nền tảng Kaggle. Thay vì phân tích riêng lẻ từng bộ dữ liệu, nhóm nghiên cứu tiến hành hợp nhất bốn tập dữ liệu độc lập, tương ứng với bốn vị trí công việc phổ biến trong lĩnh vực khoa học và phân tích dữ liệu. Cách tiếp cận này nhằm xây dựng một bộ dữ liệu có quy mô lớn hơn, đồng thời gia tăng tính đa dạng và khả năng khái quát hóa. Cụ thể, bốn bộ dữ liệu được sử dụng bao gồm:

1. Data Analyst Jobs:

- Nguồn: <https://www.kaggle.com/datasets/andrewmvd/data-analyst-jobs/data>
- Mô tả: Chứa thông tin về các vị trí tuyển dụng cho Data Analyst.

2. Data Scientist Jobs:

- Nguồn: <https://www.kaggle.com/datasets/andrewmvd/data-scientist-jobs>
- Mô tả: Chứa thông tin về các vị trí tuyển dụng cho Data Scientist.

3. Data Engineer Jobs:

- Nguồn: <https://www.kaggle.com/datasets/andrewmvd/data-engineer-jobs>
- Mô tả: Chứa thông tin về các vị trí tuyển dụng cho Data Engineer.

4. Business Analyst Jobs:

- Nguồn: <https://www.kaggle.com/datasets/andrewmvd/business-analyst-jobs>
- Mô tả: Chứa thông tin về các vị trí tuyển dụng cho Business Analyst.

5. Other Jobs:

- Nguồn: <https://www.kaggle.com/datasets/fahadrehman07/data-science-jobs-and-salary-glassdoor>
- Nguồn : <https://www.kaggle.com/datasets/rashikrahmanpritom/data-science-job-posting-on-glassdoor>
- Mô tả: Chứa thông tin về các vị trí tuyển dụng cho các vị trí khác.

Quy trình hợp nhất:

- Đầu tiên, mỗi file CSV từ các bộ dữ liệu trên được đọc vào Pandas DataFrame.
- Một cột mới, chẳng hạn job_category, được thêm vào mỗi DataFrame để đánh dấu vai trò công việc gốc (Data Analyst, Data Scientist, Data Engineer, Business Analyst).
- Các DataFrame này sau đó được nối lại (concatenated) thành một DataFrame duy nhất.
- Kiểm tra và xử lý các cột có tên giống nhau nhưng ý nghĩa khác nhau hoặc các cột trùng lặp.
- Loại bỏ các bản ghi trùng lặp hoàn toàn có thể xuất hiện sau khi hợp nhất.

Sau khi hợp nhất, bộ dữ liệu tổng hợp có khoảng 14,000 bản ghi và 26 cột (số lượng cột có thể thay đổi một chút tùy thuộc vào cách hợp nhất và các cột gốc), với tổng dung lượng khoảng **52MB**. Các cột chính thường bao gồm: **Job Title, Salary Estimate, Job Description, Rating, Company Name, Location, Headquarters, Size, Founded, Type of ownership, Industry, Sector, Revenue, Competitors, Easy Apply, Job Title Origin, Salary Min, Salary Max, Salary Avg, Location state, Headquarters state, Founded Group, Company Age, Skills, Experience và education**

STT	Tên cột	Mô tả	Kiểu giá trị
1	Job Title	Tên công việc tuyển dụng	string
2	Salary Estimate	Khoảng lương ước tính cho vị trí	string

		công việc	
3	Job Description	Mô tả vị trí công việc, yêu cầu tuyển dụng, giới thiệu công ty	string
4	Rating	Lượt đánh giá của công ty	int
5	Company Name	Tên công ty	string
6	Location	Vị trí công ty	string
7	Headquarters	Vị trí đặt trụ sở chính của công ty	string
8	Size	Quy mô (thể hiện bằng số lượng nhân viên) của công ty	string
9	Founded	Năm thành lập công ty	int
10	Type of ownership	Loại công ty	string
11	Industry	Lĩnh vực công ty	string
12	Sector	Ngành của công ty	string
13	Revenue	Doanh thu của công ty	string

14	Competitors	Các công ty làm cùng trong ngành	string
15	Easy Apply	Có dễ apply không	bool
16	Job Title Origin	Tên công việc gốc	string
17	Salary Min	Mức lương tối thiểu	int
18	Salary Max	Mức lương tối đa	Int
19	Salary Avg	Mức lương trung bình	float64
20	Location state	Bang hoặc tỉnh/thành phố nơi công việc đặt trụ sở	string
21	Headquarters state	Bang hoặc thành phố nơi đặt trụ sở chính của công ty	string
22	Founded Group	Nhóm năm thành lập công ty	string
23	Company Age	Tuổi của công ty	Int
24	skills	Danh sách các kỹ năng yêu cầu trong JD	skills
25	experience	Yêu cầu kinh nghiệm cho vị trí	string

26	education	Yêu cầu về học vấn	string
----	-----------	--------------------	--------

Bảng 3.1: Mô tả bộ dữ liệu sử dụng

3.2 Quy trình khai phá (EDA - Exploratory Data Analysis)

3.2.1 Thống kê mô tả

Bước đầu tiên là xem xét các thông tin cơ bản của bộ dữ liệu:

df.info(): Hiển thị thông tin về số lượng bản ghi, số lượng cột, tên cột, kiểu dữ liệu của mỗi cột và số lượng giá trị không null. Điều này giúp nhanh chóng xác định các cột có dữ liệu thiếu.

RangeIndex: 14161 entries, 0 to 14160

Data columns (total 27 columns):

#	Column	Non-Null Count	Dtype
0	ID	14161 non-null	int64
1	Job Title	14161 non-null	object
2	Salary Estimate	14161 non-null	object
3	Job Description	14161 non-null	object
4	Rating	14161 non-null	float64
5	Company Name	14161 non-null	object
6	Location	14161 non-null	object
7	Headquarters	14161 non-null	object
8	Size	14161 non-null	object
9	Founded	14161 non-null	int64
10	Type of ownership	14161 non-null	object
11	Industry	14161 non-null	object
12	Sector	14161 non-null	object
13	Revenue	14161 non-null	object
14	Competitors	13501 non-null	object
15	Easy Apply	12759 non-null	object
16	Job Title Origin	12759 non-null	object
17	Salary Min	14161 non-null	int64
18	Salary Max	14161 non-null	int64
19	Salary Avg	14161 non-null	float64
20	Location state	14161 non-null	object
21	Headquarters state	12759 non-null	object
22	Founded Group	12759 non-null	object
23	Company Age	14161 non-null	int64
24	skills	14159 non-null	object
25	experience	14035 non-null	object
26	education	13937 non-null	object

Hình 3.1: Thống kê mô tả dữ liệu

df.describe(): Cung cấp các thông kê mô tả cho các cột số (số lượng, trung bình, độ lệch chuẩn, min, max, các tứ phân vị).

	ID	Rating	Founded	Salary Min	Salary Max	Salary Avg	Company Age
count	14161.000000	14161.000000	14161.000000	14161.000000	14161.000000	14161.000000	14161.000000
mean	5821.257185	3.331975	1420.956218	69.395240	115.191724	92.284761	36.155497
std	3893.999195	1.508451	889.343086	30.680938	42.970457	35.821164	47.336388
min	0.000000	-1.000000	-1.000000	10.000000	16.000000	13.500000	-1.000000
25%	2138.000000	3.200000	0.000000	46.000000	82.000000	64.000000	6.000000
50%	5678.000000	3.700000	1976.000000	62.000000	106.000000	84.500000	23.000000
75%	9220.000000	4.100000	2002.000000	87.000000	141.000000	113.000000	43.000000
max	12781.000000	5.000000	2020.000000	212.000000	331.000000	271.000000	400.000000

Hình 3.2: Thống kê mô tả tần suất dữ liệu

df.isnull().sum(): Tính tổng số lượng giá trị thiếu (NaN) cho mỗi cột, giúp định lượng mức độ thiếu hụt dữ liệu.

```

Competitors      660
Easy Apply      1402
Job Title Origin 1402
Headquarters state 1402
Founded Group    1402
skills           2
experience       126
education        224
dtype: int64

Competitors      4.660688
Easy Apply      9.900431
Job Title Origin 9.900431
Headquarters state 9.900431
Founded Group    9.900431
skills           0.014123
experience       0.889768
education        1.581809
dtype: float64

```

Hình 3.3: Tổng số giá trị thiếu

3.2.2 Phân tích thuộc tính (Numerical/Quantitative Variables)

Thuộc tính	Count	Mean	Std Dev	Min	25%	50%	75%	Max
Rating	14161	3.3	1.5	-1	3.2	3.7	4.1	5
Founded	14161	1420	889	-1	0	1976	2002	2020

Bảng 3.2: Thống kê mô tả EDA

- **Thuộc tính Rating:**

- Mặc dù thuộc tính này có đầy đủ 14,161 quan sát, kết quả thống kê mô tả cho thấy sự tồn tại của vấn đề nghiêm trọng liên quan đến chất lượng dữ liệu
- Đặc biệt, giá trị cực tiểu bằng **-1** cho thấy dữ liệu khuyết đã được thay thế bằng giá trị mặc định này trong quá trình xử lý, dẫn đến nguy cơ sai lệch khi phân tích hoặc xây dựng mô hình.

- **Thuộc tính Founded:**

- Mặc dù trường dữ liệu này bao gồm đầy đủ 14,161 quan sát, các chỉ số mô tả cho thấy tồn tại vấn đề chất lượng dữ liệu đáng kể.
- Giá trị tối thiểu (**Min**) bằng **-1** — một giá trị phi lý đối với thuộc tính “**Founded**” (năm thành lập) — cho thấy các giá trị bị thiếu đã được gán tạm thời bằng **-1** trong quá trình tiền xử lý.

1.1.1.1. Đối với các thuộc tính dạng văn bản (Text Variables)

a. Job Title

Nhận xét: Thuộc tính này phản ánh tên công việc được tuyển dụng và hiện có hơn 10.000 giá trị khác nhau. Điều này cho thấy mức độ đa dạng lớn trong các vị trí tuyển dụng, đồng thời cũng đặt ra thách thức cho quá trình phân tích. Nếu không được chuẩn hóa hoặc xử lý hợp lý (ví dụ: gom nhóm theo vai trò chính, chuẩn hóa danh xưng), sự đa dạng này có thể trở thành nguồn gây nhiễu, làm giảm hiệu quả của các mô hình dự đoán.

b. Salary Estimate

Nhận xét: Đây là thuộc tính văn bản mô tả mức lương ước tính cho từng vị trí tuyển dụng, thường xuất hiện dưới dạng khoảng, chẳng hạn “\$70K–\$90K *per year*”. Từ thông tin này có thể trích xuất các đặc trưng định lượng quan trọng như mức lương tối thiểu (**Salary Min**), mức lương tối đa (**Salary Max**) và mức lương trung bình (**Salary Avg**). Tuy nhiên, dữ liệu cũng bao gồm khá nhiều **bản ghi** có định dạng khác biệt (“\$17–\$22K

per hour”), gây ra sự sai lệch trong phân tích. Do đó, cần tiến hành xử lý hoặc loại bỏ những trường hợp này để đảm bảo tính nhất quán và chất lượng của tập dữ liệu.

c. Job Description

Nhận xét: Đây là trường dữ liệu văn bản dài, phản ánh các yêu cầu kỹ năng, nhiệm vụ và tiêu chí tuyển dụng. Kết quả phân tích khám phá dữ liệu (EDA) cho thấy nhiều bản mô tả có độ dài lớn, chứa sự lặp từ, thông tin dư thừa và thiếu tính thống nhất trong cách diễn đạt giữa các nhóm công việc. Để khắc phục, nhóm dự kiến triển khai quy trình tiền xử lý văn bản gồm chuẩn hóa, loại bỏ *stopwords* và các từ ít giá trị thông tin. Bên cạnh đó, việc tận dụng các mô hình ngôn ngữ lớn (LLMs) sẽ hỗ trợ trích xuất đặc trưng ngữ nghĩa, nhằm phục vụ hiệu quả cho bài toán phân loại công việc.

d. Location

Nhận xét: Đây là thuộc tính văn bản mô tả địa điểm của công ty tuyển dụng. Với khoảng 400 giá trị khác nhau, dữ liệu phản ánh sự phân bố đa dạng về vị trí địa lý của các nhà tuyển dụng, qua đó cho thấy mức độ phân tán và đa chiều trong thị trường lao động.

e. Headquarters

Nhận xét: Đây là thuộc tính dạng văn bản phản ánh thông tin về trụ sở chính của các công ty tuyển dụng. Với hơn 1500 giá trị khác biệt, dữ liệu thể hiện sự đa dạng đáng kể trong phân bố địa lý của các doanh nghiệp, đồng thời cung cấp cơ sở để phân tích mối quan hệ giữa vị trí trụ sở và các yếu tố tuyển dụng như mức lương hay nhu cầu nhân lực.

f. Competitors

Nhận xét: Thuộc tính này thuộc dạng văn bản, chứa danh sách các công ty được xác định là đối thủ cạnh tranh của doanh nghiệp tuyển dụng. Mỗi bản ghi có thể bao gồm nhiều tên công ty, tạo nên tính chất phức tạp trong việc xử lý dữ liệu. Toàn bộ tập dữ liệu ghi nhận hơn 1000 giá trị khác biệt, phản ánh mức độ đa dạng của thị trường và mạng lưới cạnh tranh giữa các tổ chức.

1.1.1.2. Đối với các thuộc tính dạng phân loại (Categorical Variables)

a. Size

Size	Tần số (Count)
1 to 50 employees	1878
51 to 200 employees	2374
201 to 500 employees	1538
501 to 1000 employees	1281
1001 to 5000 employees	2257
5001 to 10000	813
10000+ employees	2975
Missing	991

Bảng 3.3: Tần số size

Nhận xét: **Size** là trường dữ liệu phản ánh quy mô công ty, thường được biểu diễn dưới dạng chuỗi văn bản như “**51 to 200 employees**” hoặc “**10000+ employees**”. Kết quả phân tích cho thấy tồn tại nhiều giá trị khuyết (ví dụ: **-1**, **Missing**) và sự không thống nhất trong cách biểu diễn (dạng chuỗi chưa chuẩn hóa thành số). Bên cạnh đó, việc phân nhóm quá chi tiết dẫn đến nhiều khi đưa vào mô hình học máy.

Hướng xử lý : Nhóm nghiên cứu đề xuất chuẩn hóa dữ liệu về dạng số lượng nhân sự trung bình, đồng thời gom thành ba nhóm chính: nhỏ, vừa và lớn. Các giá trị khuyết sẽ được gom chung vào một nhóm “*Missing*” nhằm duy trì tính đồng nhất và thuận lợi cho quá trình mô hình hóa.

b. Revenue

Size	Tần số (Count)
\$10+ billion (USD)	1853
\$100 to \$500 million (USD)	1436
\$50 to \$100 million (USD)	1027
\$2 to \$5 billion (USD)	820
\$10 to \$25 million (USD)	768
\$25 to \$50 million (USD)	647
\$1 to \$5 million (USD)	603
\$1 to \$2 billion (USD)	635

\$5 to \$10 billion (USD)	437
Less than \$1 million (USD)	427
\$500 million to \$1 billion (USD)	478

Bảng 3.4: Tần số Revenue

Nhận xét: Cột “Revenue” biểu thị doanh thu hằng năm của doanh nghiệp, thường được trình bày dưới dạng khoảng, chẳng hạn “\$10+ billion” hoặc “Less than \$1 million”. Kết quả phân tích cho thấy một tỷ lệ đáng kể giá trị trong cột này bị khuyết hoặc được thay thế bằng các nhãn phi chuẩn như “Unknown” hay “-1”, gây cản trở cho quá trình tiền xử lý và mô hình hóa.

Hướng xử lý: Nhóm nghiên cứu dự kiến chuẩn hóa các khoảng doanh thu thành các nhóm quy mô nhỏ, vừa và lớn, đồng thời gom toàn bộ giá trị không xác định vào một nhóm “Missing”. Cách tiếp cận này nhằm đảm bảo tính nhất quán và giảm nhiễu trong dữ liệu đầu vào của mô hình học máy.

c. Industry

Size	Tần số (Count)
IT Services	1920

Staffing & Outsourcing	1393
------------------------	------

Computer Hardware & Software	977
Consulting	677
-1	1878
Others	7,255

Bảng 3.5: Tần số Industry

Nhận xét: Thuộc tính *Industry* phản ánh lĩnh vực hoạt động chính của doanh nghiệp và thể hiện mức độ phân tán cao với nhiều giá trị khác biệt. Tuy nhiên, trong dữ liệu vẫn tồn tại một số bản ghi bị thiếu hoặc xuất hiện tên ngành không thống nhất, dẫn đến hiện tượng phân mảnh khi chuyển đổi sang dạng số. Để khắc phục, nhóm nghiên cứu dự kiến tiến hành chuẩn hóa tên ngành, xây dựng các nhóm lĩnh vực có tính chất tương đồng, đồng thời lựa chọn phương pháp mã hóa phù hợp nhằm tối ưu hóa cho quá trình huấn luyện mô hình học máy.

d. Type of ownership

Size	Tần số (Count)
------	----------------

Company - Private	7643
Company - Public	3705

Subsidiary or Business Segment	621
Nonprofit Organization	588
Government	266
College / University	182
Contract	66
Hospital	80
Private Practice / Firm	38
Other Organization	44
School / School District	24

Self-employed	11
Franchise	4

Bảng 3.6: Tần số Type of Ownership

Nhận xét: Thuộc tính *Type of Ownership* phản ánh hình thức sở hữu của doanh nghiệp, bao gồm các loại phổ biến như *Private*, *Public*, *Government* hoặc *Company - Subsidiary*. Tuy nhiên, dữ liệu quan sát cho thấy một tỷ lệ đáng kể các bản ghi bị thiếu, thường được gán dưới dạng “-1” hoặc “Unknown”, làm suy giảm độ tin cậy của thông tin trong phân tích. Để xử lý, nhóm nghiên cứu dự kiến chuẩn hóa các giá trị này và gom toàn bộ trường hợp thiếu vào một nhóm *Missing*, nhằm hạn chế nhiễu và nâng cao tính nhất quán khi sử dụng trong mô hình học máy.

e. Sector

Size	Tần số (Count)
Information Technology	4047
Business Services	2729
-1	1875
Finance	1049
Health Care	632
Biotech & Pharmaceuticals	603
Insurance	520
Manufacturing	409

Education	279
Government	226
Aerospace & Defense	295
Accounting & Legal	223
Retail	217
Media	207
Oil, Gas, Energy & Utilities	147
Transportation & Logistics	130
Telecommunications	85
Non-Profit	90
Consumer Services	72
Real Estate	62
Construction, Repair &	99

Maintenance	
Restaurants, Bars & Food Services	50
Arts, Entertainment & Recreation	28
Agriculture & Forestry	11
Travel & Tourism	25
Mining & Metals	3

Bảng 3.7: Tần số Sector


Nhận xét: thuộc tính *Sector* mô tả lĩnh vực kinh doanh trọng tâm của doanh nghiệp, với các ví dụ tiêu biểu như *Information Technology*, *Health Care*, hay *Finance*. Dữ liệu quan sát cho thấy thuộc tính này có mức độ đa dạng cao, song đồng thời tồn tại nhiều bản ghi thiếu hoặc được gán giá trị không xác định (như “-1”, “Unknown”), gây hạn chế trong việc phân tích xu hướng theo ngành. Để khắc phục, nhóm nghiên cứu đề xuất chuẩn hóa các giá trị, xây dựng nhóm ngành tương đồng và gom toàn bộ dữ liệu thiếu vào một nhóm *Missing*, qua đó đảm bảo tính nhất quán và hỗ trợ mô hình học máy đạt hiệu quả tốt hơn.

3.2.3 Phân tích biến đơn

Phân tích từng biến một cách độc lập để hiểu phân phối và đặc điểm của chúng.

- **Biến số (Numerical Variables):**


- Rating: Phân tích phân phối của thuộc tính *Rating* (thang điểm từ 1 đến 5) cho thấy phần lớn các giá trị tập trung ở mức cao, chủ yếu trong khoảng 3.5–4.5, với đỉnh phổ biến quanh 3.75–4.0. Kết quả này phản ánh xu hướng các công ty thường nhận được đánh giá tích cực từ người dùng. Tuy nhiên, dữ liệu cũng ghi nhận sự xuất hiện bất thường của một lượng đáng kể các giá trị -1 , vốn không phải là xếp hạng hợp lệ, gợi ý khả năng đây là giá trị thay thế cho dữ liệu bị thiếu. Ngược lại, số lượng công ty có xếp hạng trung bình thấp (0–2.5) lại chiếm tỷ lệ rất nhỏ, điều này có thể gây lệch phân phối và ảnh hưởng đến hiệu quả của các mô hình phân tích nếu không được xử lý thích hợp.



Hình 3.4: Biểu đồ phân bố Rating

- Salary: Đây là biến mục tiêu, thường được biểu diễn dưới dạng chuỗi kèm khoảng giá trị (ví dụ: "\$100K - \$150K"). Sau khi xử lý và chuyển đổi, phân

phối của mức lương trung bình (tính theo nghìn đô la – \$K) cho thấy dạng **phân bố lệch phải (right-skewed)**. Trên biểu đồ, trục hoành biểu diễn mức lương trung bình, trong khi trục tung thể hiện tần suất xuất hiện. Kết quả cho thấy đỉnh phân bố tập trung trong khoảng **60–70 nghìn đô la**, phản ánh đây là mức lương phổ biến nhất trong tập dữ liệu. Ở các mức lương cao hơn, tần suất xuất hiện giảm dần rõ rệt, với số lượng bản ghi có mức lương trên **175 nghìn đô la** là rất ít, thể hiện đặc điểm phân bố không cân đối của dữ liệu




Hình 3.5: Biểu đồ phân bố lương trung bình

- **Biến phân loại (Categorical Variables):**

- Job Title: Thuộc tính này biểu diễn **tên chức danh công việc** trong các tin tuyển dụng. Kết quả trực quan hóa cho thấy **20 chức danh phổ biến nhất**, trong đó *Data Analyst* chiếm tỷ trọng lớn nhất với gần **800 tin tuyển dụng**.


Các vị trí *Data Engineer* và *Business Analyst* cũng xuất hiện với tần suất cao, lần lượt khoảng **750** và **550** bản ghi. Ngoài ra, các chức danh khác thuộc nhóm công việc dữ liệu như *Data Scientist*, *Senior Data Analyst* hay *Senior Data Engineer* cũng có mặt với số lượng đáng kể, phản ánh sự đa dạng trong nhu cầu tuyển dụng nhân sự dữ liệu ở nhiều cấp bậc khác nhau.



Hình 3.6: Biểu đồ liệt kê số lượng công việc

- Location: Phân tích phân bố theo địa điểm tuyển dụng cho thấy sự tập trung rõ rệt tại một số tiểu bang. Cụ thể, Texas (TX) đứng đầu với gần 4.000 việc làm, tiếp đến là California (CA) với khoảng 3.300 việc làm. Các bang lớn khác như New York (NY), Illinois (IL), Arizona (AZ), Pennsylvania (PA), và Florida (FL) cũng ghi nhận số lượng đáng kể, dao động trong khoảng 650–1.000 việc làm. Trong khi đó, các bang còn lại trong nhóm Top 15 như

New Jersey (NJ), Ohio (OH), North Carolina (NC), Colorado (CO), Delaware (DE), Washington (WA), Virginia (VA), và Utah (UT) có số lượng tin tuyển dụng thấp hơn đáng kể, chủ yếu chỉ từ vài chục đến khoảng 200 việc làm, phản ánh sự chênh lệch lớn về nhu cầu nhân lực theo khu vực địa lý.



Hình 3.7: Biểu đồ phân bố khu vực tuyển dụng

3.2.4 Phân tích biến bội

- **Rating vs Salary Avg:** Biểu đồ phân tán thể hiện mối quan hệ giữa mức lương trung bình (Average Salary) và xếp hạng công ty (Company Rating). Trục hoành mô tả thang điểm đánh giá từ -1 đến 5, trong khi trục tung biểu diễn mức lương trung bình (tính bằng nghìn đô la). Kết quả cho thấy có một cụm điểm dữ liệu đáng kể tại mức -1, phản ánh số lượng lớn công ty không có đánh giá xếp hạng nhưng vẫn ghi nhận nhiều mức lương khác nhau. Với nhóm công ty có xếp hạng từ 3.0 đến 5.0, các điểm dữ liệu phân bố dày đặc, đặc biệt trong khoảng 3.5–4.5, đi


kèm mức lương đa dạng và thường cao hơn so với các nhóm khác. Ngược lại, dữ liệu ở các mức xếp hạng thấp (0–2.0) xuất hiện rất ít, cho thấy sự thiếu hụt thông tin và hạn chế trong việc phân tích xu hướng ở phân khúc này.



Hình 3.8: Biểu đồ phân bố giữa lương và đánh giá


- **Salary Avg vs State:** Biểu đồ hộp minh họa phân bố mức lương trung bình theo 10 tiểu bang có số lượng tuyển dụng cao nhất. Kết quả cho thấy California (CA) và Ohio (OH) đạt mức lương trung vị cao nhất, dao động trong khoảng 110–120 nghìn đô la, đồng thời phản ánh sự phân tán rộng, cho thấy mức độ đa dạng trong chính sách đãi ngộ. Các bang như New York (NY) và New Jersey (NJ) đứng sau, với lương trung vị vào khoảng 90–100 nghìn đô la. Ngược lại, Washington (WA) ghi nhận mức trung vị thấp nhất trong nhóm. Biểu đồ cũng làm nổi bật sự tồn tại của các giá trị ngoại lệ ở mức lương cao, đặc biệt tại California (CA) và Delaware

(DE), cho thấy sự chênh lệch đáng kể và biến động mạnh mẽ về mức lương giữa các khu vực địa lý.




Hình 3.9: Biểu đồ phân bố mức lương trung bình theo khu vực

- Salary Avg vs Sector:** Biểu đồ thể hiện phân bố mức lương trung bình theo 10 ngành có số lượng tuyển dụng nhiều nhất. Kết quả cho thấy “Biotech & Pharmaceuticals” và “Information Technology” nổi bật với mức lương trung vị cao nhất, dao động trong khoảng 110–120 nghìn đô la, trong đó ngành Công nghệ thông tin còn ghi nhận nhiều giá trị ngoại lệ ở mức lương rất cao, phản ánh tiềm năng thu nhập vượt trội. Ngược lại, các ngành như “Travel & Tourism” và “Retail” có mức lương trung vị thấp nhất, cho thấy sự khác biệt đáng kể về chế độ đãi ngộ. Nhìn chung, biểu đồ làm rõ sự chênh lệch thu nhập đáng kể giữa các ngành nghề, trong đó công nghệ và dược phẩm giữ vai trò dẫn đầu về mức lương và cơ hội phát triển.



Hình 3.10: Biểu đồ phân bố lương theo ngành nghề

3.2.5 Phân tích đa biến



Hình 3.11: Ma trận tương quan giữa các biến số

"Salary Min", "Salary Max", và "Salary Avg" có mối tương quan dương rất mạnh (0.89–0.98), gần đạt đến mức tuyệt đối (1.00). Điều này hoàn toàn hợp lý vì mức lương tối thiểu, tối đa và trung bình thường biến động cùng chiều trong cùng một công ty.

"Rating" và **"Founded"** có mối tương quan dương ở mức trung bình (0.43), gợi ý rằng các công ty được thành lập sớm hơn có xu hướng nhận được đánh giá cao hơn, hoặc ngược lại.

"Company Age" và **"Founded"** có tương quan dương vừa phải (0.38), phù hợp với logic vì tuổi công ty được xác định trực tiếp từ năm thành lập.

Hầu hết các đặc trưng khác thể hiện mối tương quan yếu hoặc gần như không đáng kể (≈ 0), chẳng hạn như **"Rating"** với các biến lương (≈ 0.04 – 0.05).

Ngoài ra, một số mối tương quan âm yếu cũng được ghi nhận, ví dụ **"Company Age"** với **"Salary Min"** (-0.04), **"Salary Max"** (-0.02) và **"Salary Avg"** (-0.03), cho thấy tuổi công ty hầu như không ảnh hưởng đến mức lương.

3.3 Nhận xét chất lượng bộ dữ liệu

Để đánh giá chất lượng bộ dữ liệu, cần tiến hành phân tích hiện trạng trước khi áp dụng các bước tiền xử lý, tập trung vào những yếu tố cốt lõi như quy mô dữ liệu, định dạng trường thông tin và mức độ xuất hiện giá trị khuyết thiếu.

- **Kích thước và cấu trúc:**

- Dữ liệu có kích thước tương đối lớn, với 14161 bản ghi, cung cấp đủ thông tin để phân tích.
- Các cột bao gồm Job Title, Ranking, Salary Estimate, Company Name, Location, Headquarters, Size, Founded, Type of ownership, Industry, Sector, Revenue, Competitors, Easy Apply,...

- **Kiểu dữ liệu**

Kiểu dữ liệu của các cột được tóm tắt như sau:

Cột	Kiểu dữ liệu (Dtype)	Nhận xét
Job Title	string	Cần tiến hành xử lý dữ liệu dạng text, trích xuất đặc trưng hoặc gom nhóm để giảm số lượng dữ liệu hoặc đưa về mẫu chung

Salary Estimate	string	Có định dạng rõ ràng, tồn tại nhiều, cần loại bỏ cũng như trích xuất thông tin có lợi
Job Description	string	Văn bản dạng text, rất dài và nhiều thông tin dư thừa, yêu cầu xử lý và rút trích các đặc trưng quan trọng
Rating	float	Phù hợp cho lương
Company Name	string	Không cần thiết cho dự đoán lương
Location	string	Có lượng giá trị lớn, yêu cầu trích xuất và gom nhóm phù hợp
Headquarters	string	Có lượng giá trị lớn, yêu cầu trích xuất và gom nhóm phù hợp
Size	string	Có số lượng giá trị ở ngưỡng thấp, có thể gom nhóm, phù hợp cho lương
Founded	string	Có thể trích xuất đặc trưng

Type of ownership	string	Có số lượng giá trị ở ngưỡng thấp, có thể gom nhóm, phù hợp cho lương
Industry	string	Số lượng giá trị rất nhiều, có tương quan mạnh với ‘Sector’, có thể bỏ
Sector	string	Có số lượng giá trị ở ngưỡng thấp, có thể gom nhóm, phù hợp cho lương
Revenue	string	Có số lượng giá trị ở ngưỡng thấp, có thể gom nhóm, phù hợp cho lương
Competitors	string	Chứa thông tin về các công ty chung ngành, không cần thiết cho dự đoán lương
Easy apply	bool	Chứa lượng lớn giá trị null, không phù hợp dự đoán

Bảng 3.8: Kiểu dữ liệu các cột

- **Giá trị thiếu (NaN)**

Đây là một thách thức đáng kể trong bộ dữ liệu trước khi tiền xử lý, đòi hỏi việc xem xét chi tiết miền giá trị của từng thuộc tính để nhận diện các bất thường và đảm bảo tính hợp lệ.

Cột	Số lượng NaN	Tỷ lệ NaN (trên tổng số dòng)	Nhận xét
Job Title	1402	~9.9	Trung bình
Rating	91	~0.80%	Thấp
Salary Estimate	398	~3.50%	Trung bình
Job Description	2379	~20.91%	Đáng kể

Bảng 3.9: Giá trị NaN

Số lượng giá trị thiếu phân bố không đồng đều giữa các cột. Trong đó, Job Description có tỷ lệ thiếu cao nhất (20.91%), tiếp đến là Salary Estimate (3.50%) và Job Title (9.9%). Ngược lại, Rating có tỷ lệ thiếu rất thấp (0.80%), gần như không ảnh hưởng đáng kể đến phân tích. Như vậy, vấn đề dữ liệu thiếu chủ yếu tập trung ở các trường mô tả văn bản, đặc biệt là Job Description, đòi hỏi cần có chiến lược xử lý phù hợp để đảm bảo chất lượng dữ liệu.

CHƯƠNG 4 :PHƯƠNG PHÁP ĐỀ XUẤT


4.1 Mô hình

4.1.1 Random Forest

Random Forest là một thuật toán học máy thuộc nhóm ensemble learning, phát triển dựa trên cơ sở của cây quyết định (Decision Tree). Thay vì tạo ra một cây quyết định duy nhất, thuật toán này xây dựng một tập hợp nhiều cây quyết định độc lập, gọi là “rừng”. Mỗi cây được huấn luyện trên một tập con dữ liệu ngẫu nhiên thông qua kỹ thuật bootstrap aggregating (bagging) và chỉ xem xét một tập con ngẫu nhiên các đặc trưng khi thực hiện các bước phân tách

Quá trình hoạt động của Random Forest bao gồm các bước sau:

1. **Lấy mẫu Bootstrap:** Từ tập dữ liệu huấn luyện gốc, tạo ra N tập con thông qua phương pháp **lấy mẫu có thay thế (bootstrap sampling)**. Mỗi tập con có kích thước tương đương với tập dữ liệu gốc và có thể chứa các mẫu lặp lại.
2. **Xây dựng cây quyết định:** Với mỗi tập con, một cây quyết định được xây dựng. Tuy nhiên, tại mỗi nút phân chia, chỉ xem xét một **tập con ngẫu nhiên các đặc trưng** thay vì toàn bộ các thuộc tính. Cơ chế này giúp tăng tính ngẫu nhiên và giảm mức độ tương quan giữa các cây trong rừng.
3. **Dự đoán:**
 - **Phân loại:** Mỗi cây đưa ra dự đoán về lớp của mẫu. Kết quả cuối cùng được xác định bằng cách áp dụng bỏ phiếu đa số (majority voting) từ tất cả các cây.
 - **Hồi quy:** Giá trị dự đoán cuối cùng được tính bằng trung bình các dự đoán từ tất cả các cây trong rừng.



Hình 4.1: Mô hình Random forest

Ưu điểm:


- **Giảm thiểu quá khớp:** Nhờ việc kết hợp nhiều cây quyết định và áp dụng cơ chế ngẫu nhiên, Random Forest có khả năng hạn chế hiện tượng quá khớp tốt hơn nhiều so với một cây quyết định đơn lẻ.
- **Tính ổn định cao:** Mô hình ít bị ảnh hưởng bởi nhiễu hoặc các điểm dữ liệu ngoại lai so với cây quyết định đơn.
- **Xử lý đa dạng dữ liệu:** Thuật toán có thể làm việc trực tiếp với cả dữ liệu định tính và định lượng mà không yêu cầu nhiều bước tiền xử lý phức tạp.
- **Đánh giá mức độ quan trọng của đặc trưng:** Random Forest cung cấp khả năng ước lượng mức độ ảnh hưởng của từng thuộc tính đối với kết quả dự đoán.
- **Hiệu quả trong thực tiễn:** Mô hình thường đạt hiệu suất cao trên nhiều loại bài toán khác nhau, từ phân loại đến hồi quy.

Nhược điểm:

- **Khó giải thích:** Do mô hình bao gồm nhiều cây quyết định, việc hiểu và lý giải nguyên nhân một dự đoán cụ thể trở nên phức tạp hơn so với việc sử dụng một cây đơn lẻ.
- **Yêu cầu tài nguyên cao:** So với một cây quyết định, Random Forest đòi hỏi nhiều bộ nhớ và công suất tính toán hơn, đặc biệt khi số lượng cây trong rừng tăng lên.
- **Hiệu năng có thể giảm với dữ liệu lớn:** Khi làm việc với tập dữ liệu rất lớn và nhiều cây, thời gian huấn luyện có thể kéo dài đáng kể.

4.1.2 LightGBM

LightGBM là một framework thuộc nhóm Gradient Boosting được phát triển bởi Microsoft, nhằm tối ưu hóa hiệu suất trên các tập dữ liệu lớn. Khác với XGBoost, vốn xây dựng cây theo chiều ngang (level-wise/depth-wise), LightGBM áp dụng chiến lược xây dựng cây theo chiều dọc (leaf-wise). Cách tiếp cận này tập trung vào việc mở rộng các nhánh lá có lợi ích thông tin cao nhất (information gain), thay vì mở rộng toàn bộ các nút cùng cấp, giúp tăng hiệu quả học và khả năng dự đoán.



Hình 4.2: Mô hình LightGBM

Công thức:

$$\hat{y} = \sum_{i=1}^n h(\cdot; \theta_i) = \hat{y}_{-1} + h(\cdot; \theta_n)$$

Trong đó :

λ : Trọng số của mô hình cơ sở thứ i (tương tự như các λ trước đó).

$\hat{y}_{-1}$: Giá trị dự đoán của ensemble sau khi đã cộng tổng của $n - 1$ mô hình cơ sở đầu tiên.

n : Số lượng mô hình cơ sở trong ensemble

$h(\cdot; \theta_i)$: Mô hình cơ sở thứ i (ví dụ: một cây quyết định nhỏ) với các tham số θ_i .

η : Learning rate (tốc độ học) cho mô hình cơ sở thứ i . Tham số này điều chỉnh mức ảnh hưởng của mô hình mới vào dự đoán tổng thể.

Các cải tiến chính của LightGBM so với các thuật toán Boosting khác:

1. **Phát triển cây theo lá (Leaf-wise growth):** Thay vì mở rộng cây theo từng cấp độ (level-wise), LightGBM lựa chọn các nút lá có độ lợi thông tin cao nhất để phân tách. Cách tiếp cận này giúp giảm sai số dự đoán hiệu quả hơn so với phương pháp level-wise, nhưng có thể tạo ra cây sâu hơn và tăng nguy cơ quá khớp, do đó cần các tham số điều chỉnh phù hợp.
2. **Thuật toán dựa trên histogram (Histogram-based algorithm):** Thay vì tìm điểm phân tách tối ưu trên toàn bộ dữ liệu liên tục, LightGBM chia các giá trị thuộc tính thành các thùng rời rạc (bins). Phương pháp này không chỉ tăng tốc độ tính toán mà còn giảm nhu cầu bộ nhớ.
3. **Gradient-based One-Side Sampling (GOSS):** Để giảm số lượng mẫu mà vẫn duy trì độ chính xác, GOSS ưu tiên lựa chọn các mẫu có gradient lớn (tức là những mẫu mà mô hình dự đoán sai nhiều) và lấy mẫu ngẫu nhiên từ các mẫu còn lại, giúp tiết kiệm tài nguyên tính toán.
4. **Exclusive Feature Bundling (EFB):** Để giảm số lượng thuộc tính, EFB nhóm các thuộc tính độc quyền (không xuất hiện giá trị khác 0 đồng thời) thành các bó (bundles), từ đó giảm số lượng thuộc tính thực tế mà mô hình cần xử lý mà không làm mất thông tin quan trọng.

Ưu điểm:

- **Tốc độ huấn luyện nhanh:** LightGBM thực hiện huấn luyện nhanh hơn đáng kể so với XGBoost, đặc biệt khi làm việc với các tập dữ liệu lớn.
- **Sử dụng bộ nhớ hiệu quả:** Nhờ áp dụng thuật toán dựa trên histogram và kỹ thuật Exclusive Feature Bundling (EFB), LightGBM giảm đáng kể nhu cầu bộ nhớ.
- **Hiệu suất dự đoán cao:** Mô hình đạt được hiệu suất cạnh tranh so với XGBoost và các thuật toán Gradient Boosting khác.
- **Xử lý biến phân loại trực tiếp:** Có khả năng làm việc trực tiếp với các biến phân loại mà không cần chuyển đổi sang dạng one-hot encoding.

- **Khả năng mở rộng với dữ liệu lớn:** Thiết kế của LightGBM phù hợp để xử lý các tập dữ liệu quy mô lớn mà vẫn duy trì hiệu quả tính toán và dự đoán.

Nhược điểm:

- **Dễ bị quá khớp với tập dữ liệu nhỏ:** Do cách phát triển cây theo lá, nếu không kiểm soát độ sâu và số lượng lá, LightGBM có thể dễ bị quá khớp hơn trên các tập dữ liệu nhỏ.
- **Không ổn định với dữ liệu thưa thớt (sparse data):** Mặc dù hiệu quả với dữ liệu lớn, nhưng với dữ liệu thưa thớt, có thể không tối ưu bằng các thuật toán khác.
- **Nhạy cảm hơn với tham số:** Việc tinh chỉnh các tham số đòi hỏi kinh nghiệm để tránh quá khớp và đạt hiệu suất tối ưu.

4.1.3 CatBoost

CatBoost (Categorical Boosting) là một thuật toán thuộc nhóm Gradient Boosting được phát triển bởi Yandex. Tên gọi “CatBoost” phản ánh khả năng đặc biệt của thuật toán trong việc xử lý các biến phân loại (categorical features) một cách hiệu quả. CatBoost giải quyết các vấn đề thường gặp trong xử lý biến phân loại, chẳng hạn như việc one-hot encoding làm tăng số chiều dữ liệu hoặc target encoding có thể dẫn đến hiện tượng rò rỉ thông tin (data leakage).

Các điểm đặc trưng của CatBoost:

1. Xử lý biến phân loại sáng tạo (Ordered Target Encoding):

- Thay vì sử dụng one-hot encoding hay target encoding thông thường, CatBoost áp dụng một phương pháp mã hóa theo thứ tự. Với mỗi mẫu, giá trị mã hóa của một biến phân loại được xác định dựa trên các giá trị mục tiêu của các mẫu trước đó trong một thứ tự ngẫu nhiên của tập dữ liệu. Cách tiếp cận này giúp tránh rò rỉ thông tin và nâng cao khả năng tổng quát của mô hình.

- CatBoost cũng tự động xử lý các kết hợp của các biến phân loại, nhờ đó nắm bắt được các tương tác phức tạp giữa các thuộc tính.

2. Cây quyết định đối xứng (Oblivious Trees):

- Thuật toán sử dụng các cây vô thức, trong đó cùng một tiêu chí phân chia áp dụng cho tất cả các nút ở cùng một cấp độ. Điều này giúp giảm nguy cơ quá khớp, tạo cấu trúc cây cân bằng và đơn giản, đồng thời tăng tốc độ dự đoán.

3. Gradient Boosting theo thứ tự (Ordered Boosting):

- Để tránh hiện tượng dự đoán thiên lệch do tính toán gradient trên cùng tập dữ liệu đã dùng cho cây trước, CatBoost áp dụng một cơ chế đặc biệt: mỗi cây mới được huấn luyện trên các gradient được tính từ phiên bản "thuần túy" của mô hình, không bị ảnh hưởng bởi cây hiện tại hay các cây trước đó trên cùng tập con. Kỹ thuật này giúp ngăn ngừa overfitting và nâng cao khả năng tổng quát của mô hình.

Ưu điểm:

- **Xử lý biến phân loại vượt trội:** Điểm mạnh nổi bật của CatBoost là khả năng tự động và hiệu quả trong việc xử lý các biến phân loại, từ đó giảm thiểu nhu cầu tiền xử lý phức tạp.
- **Giảm nguy cơ quá khớp:** Các cơ chế như Oblivious Trees và Ordered Boosting giúp mô hình hạn chế hiện tượng quá khớp so với các thuật toán Boosting truyền thống.
- **Hiệu suất cạnh tranh:** CatBoost cung cấp hiệu suất dự đoán tương đương hoặc tốt hơn so với XGBoost và LightGBM trên nhiều loại bài toán.
- **Ít yêu cầu tinh chỉnh tham số:** So với các thuật toán Boosting khác, CatBoost thường đạt hiệu suất cao mà không cần nhiều điều chỉnh tham số.
- **Hỗ trợ GPU:** Mô hình có khả năng huấn luyện trên GPU, giúp tăng tốc quá trình đào tạo đáng kể.

Nhược điểm:

- **Tốc độ huấn luyện có thể chậm hơn:** Mặc dù được tối ưu hóa, các kỹ thuật xử lý biến phân loại và boosting có thứ tự đôi khi có thể làm cho CatBoost chậm hơn XGBoost hoặc LightGBM trên một số tập dữ liệu nhất định, đặc biệt là khi không có nhiều biến phân loại hoặc dữ liệu đã được tiền xử lý tốt.
- **Sử dụng bộ nhớ cao hơn:** Do các kỹ thuật mã hóa biến phân loại và lưu trữ dữ liệu, CatBoost có thể sử dụng nhiều bộ nhớ hơn so với các đối thủ.
- **Cấu trúc cây ít linh hoạt:** Do sử dụng Oblivious Trees, cấu trúc cây ít linh hoạt hơn, có thể không nắm bắt được tất cả các mối quan hệ phức tạp như các cây không đối xứng.

4.2 Công nghệ sử dụng

Để thực hiện đề tài, nhóm đã sử dụng một loạt các công nghệ và thư viện phổ biến trong lĩnh vực khoa học dữ liệu:

- **Môi trường thực thi:**

Google Colab / Kaggle Notebooks: Cung cấp nền tảng Python trên đám mây với GPU/TPU miễn phí, thuận tiện cho việc huấn luyện các mô hình học máy và xử lý dữ liệu lớn mà không cần phần cứng cục bộ mạnh.

- **Xử lý và khai phá dữ liệu:**

- Python: Ngôn ngữ lập trình chính được sử dụng trong nghiên cứu.
- Pandas: Thư viện cốt lõi cho thao tác và phân tích dữ liệu dạng bảng (DataFrame), bao gồm đọc/ghi file, làm sạch dữ liệu, hợp nhất, nhóm và biến đổi dữ liệu.
- NumPy: Cung cấp cấu trúc mảng đa chiều và các hàm toán học hiệu suất cao, nền tảng cho các tính toán khoa học.
- PySpark: API Python cho Apache Spark, hỗ trợ xử lý dữ liệu lớn phân tán, thích hợp với các bộ dữ liệu quá lớn mà Pandas không thể xử lý hiệu quả trên máy đơn.

- **Trực quan hóa dữ liệu:**

- Matplotlib: Thư viện cơ bản và linh hoạt cho việc tạo biểu đồ tĩnh, động và tương tác.
- Seaborn: Xây dựng dựa trên Matplotlib, cung cấp giao diện cao cấp hơn để trực quan hóa dữ liệu thống kê một cách hấp dẫn.
- WordCloud: Thư viện dùng để tạo đám mây từ, minh họa tần suất xuất hiện của các từ trong văn bản.

- **Xử lý ngôn ngữ tự nhiên (NLP) và mô hình ngôn ngữ lớn (LLM):**

- Scikit-learn (TfidfVectorizer): Chuyển đổi văn bản thành vector số học bằng phương pháp TF-IDF (Term Frequency-Inverse Document Frequency), một kỹ thuật kinh điển nhưng hiệu quả.
- Google Gemini API: Cung cấp giao diện lập trình để tương tác với mô hình ngôn ngữ lớn Gemini của Google, hỗ trợ trích xuất thông tin có cấu trúc (kỹ năng, kinh nghiệm, học vấn) từ mô tả công việc thông qua các prompt thiết kế phù hợp.

- **Học máy:**

- Scikit-learn: Cung cấp công cụ tiện ích cho học máy như chia dữ liệu, đánh giá mô hình, pipeline và bộ biến đổi.
- Spark MLlib: Thư viện cho các thuật toán học máy và hỗ trợ xây dựng pipeline trên dữ liệu lớn.
- LightGBM Library: Triển khai thuật toán LightGBM.
- CatBoost Library: Triển khai thuật toán CatBoost.

CHƯƠNG 5: THỰC NGHIỆM

5.1 Quy trình thực nghiệm

5.1.1 Xử lý dữ liệu

Bước 1: Xử lý lỗi lệch cột trong file BusinessAnalyst.csv

Việc xử lý dữ liệu CSV không đồng nhất về số cột là một vấn đề kỹ thuật quan trọng cần giải quyết trước khi phân tích. Khi đọc file CSV, nếu một số hàng chứa số lượng dấu phân tách (ví dụ: dấu phẩy) không khớp với số cột dự kiến, dữ liệu ở các hàng đó có thể bị lệch sang các cột sai, dẫn đến lỗi trong quá trình xử lý tiếp theo.

- **Phát hiện lỗi:** Kiểm tra số lượng cột trong từng hàng khi đọc file hoặc sử dụng các công cụ chuyên dụng để xác định các hàng bị lệch
- **Xử lý lỗi:**
 - Đọc file CSV với các tùy chọn cho phép bỏ qua hoặc xử lý các hàng lỗi (ví dụ: trong Pandas có thể sử dụng các phương pháp thay thế cho(`error_bad_lines=False`) do tùy chọn này đã lỗi thời).
 - Sau khi đọc, tiến hành kiểm tra và sửa chữa các hàng bị ảnh hưởng, bằng cách loại bỏ, điền giá trị thiếu, hoặc điều chỉnh lại số cột để dữ liệu đồng nhất.

Bước 2: Xử lý cột Salary Estimate

Cột này thường có định dạng như "\$70K-120K (Glassdoor est.)".

- Chuyển đổi đơn vị: Thay ký hiệu "K" bằng "000" để đưa các giá trị về dạng số thực tế.
- Tách khoảng giá trị: Phân tách chuỗi thành hai cột riêng biệt: `min_salary` và `max_salary`.

- Chuyển đổi kiểu dữ liệu: Chuyển các giá trị này sang dạng số học (integer hoặc float) để thuận tiện cho các phép tính tiếp theo.
- Tính mức lương trung bình: Tạo cột avg_salary bằng công thức

Xử lý các giá trị đặc biệt: Với các giá trị không hợp lệ hoặc placeholder như -1, có thể thay bằng NaN hoặc sử dụng các phương pháp thống kê như trung bình/trung vị để điền vào.

Bước 3: Xử lý cột Company Name

- Loại bỏ ký tự đặc biệt và xuống dòng: Các ký tự không mong muốn như \n, tab, hoặc các ký tự đặc biệt khác được loại bỏ để chuẩn hóa chuỗi văn bản.
- Loại bỏ phần xếp hạng dính liền với tên: Nếu tên chứa thông tin xếp hạng (ví dụ: "n4.5"), phần này cần được tách hoặc loại bỏ để giữ lại chỉ thông tin tên.

Bước 4: Xử lý cột Size, Type of ownership, Industry, Sector, Revenue

Các cột này thuộc dạng biến phân loại (categorical variables). Quá trình xử lý bao gồm:

- Xử lý giá trị không xác định: Các giá trị như "-1" hoặc "Unknown" có thể được coi là một hạng mục riêng ("Unknown"), điền bằng giá trị phổ biến nhất (mode), hoặc áp dụng các phương pháp imputation phức tạp hơn.
- Chuyển đổi biến khoảng: Với các cột như Size và Revenue có giá trị theo khoảng, có thể chuyển chúng thành biến thứ tự (ordinal) hoặc áp dụng one-hot encoding để sử dụng trong mô hình.

Bước 5: Xử lý cột Location và Headquarters

- Tách thông tin: Chia cột Location thành City và State (nếu có thể).
- Chuẩn hóa: Thống nhất tên các bang và thành phố để đảm bảo dữ liệu đồng nhất.

- Tạo biến mới: Có thể tạo biến `same_location` với giá trị 1 nếu `Location == Headquarters`, 0 nếu khác, nhằm đánh giá liệu công việc có đặt tại trụ sở chính hay không.

Bước 6: Xử lý giá trị thiếu (NaN)

Hai phương án được thử nghiệm:

- Loại bỏ giá trị thiếu: Xóa các hàng chứa giá trị NaN nếu số lượng không lớn.
- Imputation: Sử dụng các công cụ Imputer (trong Spark) để điền giá trị thay thế.

Bước 7: Xử lý cột Job Description (Phương pháp TF-IDF - *Ban đầu*)

- Tiền xử lý văn bản: Loại bỏ dấu câu, chuyển thành chữ thường, và loại bỏ các stop words (từ phổ biến nhưng ít ý nghĩa như "the", "is", "a").
- Tokenization: Tách văn bản thành các từ (tokens).
- Lemmatization/Stemming: Chuyển từ về dạng gốc (ví dụ: 'running' → 'run').
- TF-IDF Vectorization: Sử dụng `TfidfVectorizer` để chuyển đổi tập mô tả công việc thành ma trận số, mỗi hàng là một JD, mỗi cột là một từ, giá trị là điểm TF-IDF.
- Nhược điểm: Ma trận TF-IDF thường rất lớn và thưa thớt (nhiều số 0), chứa nhiều nhiễu và không nắm bắt được ngữ nghĩa, dẫn đến hiệu suất mô hình không cao.

Bước 8: Xử lý cột Job Description (Phương pháp LLM - Gemini)

Do TF-IDF hạn chế trong việc trích xuất ngữ nghĩa, nhóm đã sử dụng mô hình ngôn ngữ lớn (LLM) để trích xuất thông tin có cấu trúc:

Mục tiêu: Trích xuất các thông tin cốt lõi:

- Skills keyword: Từ khóa kỹ năng.
- Experience in years: Số năm kinh nghiệm.

- Education level: Trình độ học vấn.

Phương pháp: Sử dụng Google Gemini API kết hợp với Prompt Engineering để hướng dẫn mô hình trả về dữ liệu đúng định dạng JSON: {"skills": "", "experience": "", "education": ""}

- Quy trình thực hiện:
 - Lặp qua từng JD trong dataset.
 - Ghép prompt với nội dung JD.
 - Gửi yêu cầu đến Gemini API.
 - Nhận kết quả (chuỗi JSON).

Xử lý kết quả:

- Kiểm tra định dạng JSON.
- Parse chuỗi JSON để trích xuất skills, experience, education.
- Lọc bỏ các kết quả không hợp lệ; các trường hợp đặc biệt có thể xử lý thủ công hoặc bằng quy tắc bổ sung.
- Tạo các cột mới trong DataFrame để lưu trữ thông tin trích xuất.

Ưu điểm của LLM:

- Hiểu ngữ cảnh và ngữ nghĩa tốt hơn TF-IDF.
- Trích xuất thông tin cụ thể (năm kinh nghiệm, bậc học) thay vì chỉ dựa trên tần suất từ.
- Giảm số chiều dữ liệu so với TF-IDF, tạo ra các đặc trưng có ý nghĩa hơn.

Thách thức:

- Tốc độ xử lý có thể chậm hơn TF-IDF khi dữ liệu lớn.
- Độ chính xác phụ thuộc vào chất lượng prompt và khả năng của LLM.

Bước 9 (Xử lý Kỹ năng): Cột skills chứa nhiều từ khóa, cần được xử lý.

Sau khi thực hiện trực quan hóa các kỹ năng bằng WordCloud, nhóm nghiên cứu tiến hành gom các kỹ năng xuất hiện trên WordCloud thành các nhãn phân loại tương ứng. Quá trình này giúp hệ thống hóa thông tin, từ việc nhận diện các từ khóa riêng lẻ trong WordCloud sang việc tạo ra các danh mục kỹ năng chuẩn hóa, phục vụ cho việc phân loại, phân tích thống kê, và sử dụng trong các mô hình học máy.

```
skill_groups = {  
    'Programming': ['python', 'java', 'scala', 'c', 'sql', 'pl sql', 'r'],  
    'Databases': ['sql server', 'sql', 'database', 'nosql', 'relational database', 'data warehouse', 'oracle', 'ms access'],  
    'Big_Data': ['spark', 'hadoop', 'hive', 'kafka', 'big data'],  
    'Cloud': ['aws', 'azure', 'gcp'],  
    'BI_Viz': ['tableau', 'power bi', 'visualization', 'reporting', 'business intelligence', 'bi', 'qlik'],  
    'ML_Stats': ['machine learning', 'deep learning', 'statistical analysis', 'statistics', 'predictive modeling', 'sas', 'data mining', 'analytics', 'analytic'],  
    'Office_Productivity': ['excel', 'microsoft office', 'office suite', 'powerpoint', 'ms office'],  
    'Data_Eng_Mgmt': ['etl', 'data pipeline', 'data modeling', 'data governance', 'data management', 'data quality', 'data warehousing'],  
    'Project_Mgmt': ['project management', 'agile', 'scrum'],  
    'CRM_ERP': ['salesforce', 'sap']  
}
```

Hình 5.1 : Trích xuất skill,exp,edu

Sau khi xác định các nhãn phân loại kỹ năng, nhóm nghiên cứu sử dụng Regular Expression (Regex) để kiểm tra xem từng mô tả công việc có chứa các nhóm kỹ năng này hay không. Dựa trên kết quả kiểm tra, mỗi nhóm kỹ năng được mã hóa nhị phân: giá trị 1 nếu kỹ năng xuất hiện trong mô tả công việc, và 0 nếu không. Phương pháp này cho phép chuyển thông tin văn bản phi cấu trúc thành các đặc trưng số học, thuận tiện cho việc phân tích và xây dựng mô hình học máy.

Cụ thể:

	Programming	Databases	Big_Data	Cloud	BI_Viz	ML_Stats	Office_Productivity	Data_Eng_Mgmt	Project_Mgmt	CRM_ERP
0	0	0	0	0	0	0	0	0	1	0
1	0	1	0	0	0	0	1	0	0	1
2	1	1	0	0	0	0	0	0	0	0
3	0	0	0	0	0	0	0	0	0	0
4	0	0	0	0	1	0	1	0	0	0
...	...	...	...	...	...	...	...	...	...	...
12754	0	0	0	1	0	0	0	1	0	0
12755	1	1	0	0	0	1	1	1	0	0
12756	1	1	0	0	0	0	0	0	0	0
12757	1	1	0	0	0	0	0	0	0	0
12758	0	0	0	0	0	0	0	0	1	0

Hình 5.2: Phân loại kỹ năng

Sau đó chúng tôi ghép vào dữ liệu cũ bằng index của dữ liệu sau xử lý.

Bước 10 (Xử lý các biến khác):

experience: Chuẩn hóa thành dạng số.

Cột experience được chuẩn hóa thành dạng số. Do các giá trị thường biểu diễn dưới dạng khoảng năm (ví dụ: 2-4, 2+), nhóm nghiên cứu quyết định sử dụng năm nhỏ nhất trong khoảng làm đại diện cho biến này. Cách tiếp cận này cho phép biến đổi các dữ liệu văn bản không đồng nhất thành giá trị số nguyên, thuận tiện cho việc phân tích và xây dựng mô hình học máy.

```
def get_smallest_experience_number(experience_string):
    """
    Identifies the smallest number in a string and returns it.

    Args:
        experience_string: The string to extract numbers from.

    Returns:
        The smallest integer found in the string, or None if no integers are found.
    """
    if pd.isna(experience_string):
        return None
    # Find all integers in the string
    numbers = re.findall(r'\d+', str(experience_string))
    if numbers:
        # Convert to integers and find the minimum
        return min(int(num) for num in numbers)
    else:
        return None
```

Hình 5.3: Xử lý giá trị exp

education: Mã hóa thứ tự hoặc one-hot.

Tương tự như đối với experience, nhóm nghiên cứu tiến hành phân tích cột skills bằng cách trực quan hóa các kỹ năng thường xuất hiện thông qua WordCloud. Dựa trên kết quả này, các từ khóa phổ biến được tổng hợp và chuyển thành các nhãn phân loại chuẩn hóa, nhằm hệ thống hóa thông tin và phục vụ cho việc mã hóa nhị phân trong các bước phân tích tiếp

theo.

```
edu_map = {
    'PhD': ['phd', 'ph d', 'doctorate', 'pharm d'],
    'Masters': ['master', 'masters', 'ms', 'ma', 'msc', 'mba', 'mph', 'graduate degree', 'advanced degree'],
    'Bachelors': ['bachelor', 'bachelors', 'bs', 'ba', 'bsc', 'b tech', 'undergraduate', 'college degree', 'university degree'],
    'Associates': ['associate', 'technical degree'],
    'HighSchool': ['high school', 'diploma', 'ged']
}
edu_order = {'PhD': 5, 'Masters': 4, 'Bachelors': 3, 'Associates': 2, 'HighSchool': 1}
```

Hình 5.4: Gán giá trị cho nhóm kỹ năng

Chúng tôi sẽ lấy trình độ học vấn cao nhất để thay thế giá trị ban đầu.

Các biến categorical khác: Sử dụng LabelEncoder.

```
def processing(X, categorical_features):
    # Select numerical columns from the original DataFrame
    numerical_features = X.select_dtypes(include=np.number).columns.tolist()
    X_num = X[numerical_features].copy()

    # Process categorical features
    from sklearn.preprocessing import LabelEncoder
    X_cat = X[categorical_features].copy()
    for col in X_cat.columns:
        X_cat[col] = LabelEncoder().fit_transform(X_cat[col].astype(str))

    # Combine numerical and processed categorical DataFrames
    # Ensure both DataFrames have the same index for correct merging
    X_processed = pd.concat([X_num, X_cat], axis=1)

    return X_processed
```

Hình 5.5: Sử dụng LabelEncode

Bước 11: Xuất dataset đã xử lý

Sau khi hoàn thành tất cả các bước tiền xử lý, bộ dữ liệu được làm sạch và chuẩn hóa được lưu lại thành một file mới (data_job_DFmodel.csv). Bộ dữ liệu này có các đặc điểm:

- Không còn lỗi lệch cột: Các vấn đề về số lượng cột không đồng nhất đã được xử lý.
- Xử lý dữ liệu thiếu: Các giá trị thiếu đã được loại bỏ hoặc điền giá trị thay thế phù hợp.
- Chuẩn hóa biến số: Các biến số đã được chuyển về dạng chuẩn (standardized) khi cần thiết.
- Xử lý biến phân loại: Các biến categorical đã được xử lý; có thể tiếp tục áp dụng mã hóa (encoding) trong bước xây dựng mô hình.
- Trích xuất thông tin quan trọng từ JD: Các đặc trưng từ cột Job Description đã được chuẩn hóa và trích xuất, bao gồm kỹ năng, kinh nghiệm và trình độ học vấn.
- Sẵn sàng cho mô hình học máy: Bộ dữ liệu hiện đã phù hợp để đưa vào các thuật toán học máy, từ các mô hình truyền thống đến các mô hình ensemble hoặc LLM.

5.1.2 Chuẩn bị dữ liệu cho mô hình

Trước khi huấn luyện, cần thực hiện thêm một số bước:

Chọn đặc trưng (Feature Selection):

- Xác định các cột sẽ được sử dụng làm đầu vào (X) và cột mục tiêu (y).
- Cột mục tiêu là Salary Avg cho bài toán hồi quy.
- Các cột đầu vào X bao gồm các biến số và biến phân loại đã được xử lý.
- Nhóm nghiên cứu đã tính toán hệ số tương quan giữa các biến và cột mục tiêu, từ đó lựa chọn 13 đặc trưng quan trọng để đưa vào mô hình.
- **Phân chia Dữ liệu (Train-Test Split):** Chia bộ dữ liệu thành tập huấn luyện (train set, valid) và tập kiểm tra (test set) bằng `train_test_split`. Chúng tôi dùng tỷ lệ 70/15/15. Điều này đảm bảo mô hình được đánh giá trên dữ liệu mà nó chưa từng thấy.

5.2 Độ đo đánh giá

5.2.1 Các Độ đo Đánh giá Chính

Trong bài toán hồi quy, mục tiêu là dự đoán giá trị liên tục. Do đó, các độ đo đánh giá tập trung vào việc định lượng sự khác biệt giữa giá trị dự đoán và giá trị thực tế. Trong nghiên cứu này, các độ đo chính được sử dụng bao gồm:

- Căn bậc hai của sai số bình phương trung bình (Root Mean Squared Error - RMSE)
- Định nghĩa: RMSE là căn bậc hai của

MSE. Công thức: $RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$

- Ý nghĩa: RMSE đưa sai số về cùng đơn vị với biến mục tiêu, giúp việc diễn giải trở nên trực quan và dễ hiểu hơn so với MSE. Tương tự MSE, RMSE cũng nhạy cảm với các lỗi lớn; giá trị RMSE thấp hơn biểu thị mô hình có độ chính xác cao hơn.
- Ưu điểm: Cùng đơn vị với biến mục tiêu, dễ giải thích và so sánh.
- Nhược điểm: Vẫn nhạy cảm với các giá trị ngoại lệ (outliers).
- Hệ số xác định (R-squared - R^2):
- Định nghĩa: R^2 là một độ đo thống kê phản ánh mức độ phù hợp của mô hình hồi quy với dữ liệu thực tế. Nó biểu thị tỷ lệ phương sai của biến mục tiêu được giải thích bởi các biến độc lập trong mô hình.

- Công thức: $R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$

Ý nghĩa:

- Giá trị R^2 nằm trong khoảng từ 0 đến 1, với giá trị càng gần 1 cho thấy mô hình giải thích được phần lớn sự biến động của biến mục tiêu.

- Một R^2 cao thường biểu thị mô hình có khả năng dự đoán tốt.
- Tuy nhiên, R^2 cũng có thể nhận giá trị âm nếu mô hình hoạt động kém hơn việc sử dụng giá trị trung bình làm dự đoán.

• **Ưu điểm:**

- Cung cấp cái nhìn tổng quan về **khả năng giải thích dữ liệu** của mô hình.

• **Nhược điểm:**

- R^2 có thể tăng lên khi thêm nhiều biến độc lập, ngay cả khi những biến này **không mang ý nghĩa thống kê**, dẫn đến đánh giá quá lạc quan về mô hình.

5.2.2 Độ đo chính xác khoảng

Trong các bài toán hồi quy, việc đánh giá hiệu suất mô hình thường dựa vào các độ đo truyền thống như hệ số xác định (R^2) hay sai số căn bậc hai trung bình (RMSE). Mặc dù các độ đo này cung cấp thông tin định lượng về mức độ phù hợp của mô hình với dữ liệu, chúng khá trừu tượng và khó diễn giải về ý nghĩa thực tiễn, đặc biệt trong các ứng dụng cần đánh giá xem dự đoán có “đủ tốt” hay không, thay vì chỉ dựa vào mức độ chính xác tuyệt đối.

Để khắc phục hạn chế này, nghiên cứu đề xuất một độ đo mới, gọi là Độ đo Chính xác Khoảng (Range Accuracy Metric – RAM). RAM là một độ đo nhị phân, tập trung vào việc xác định liệu giá trị dự đoán của mô hình hồi quy có nằm trong một khoảng chấp nhận được hay không.

Cụ thể, trong bài toán **ước lượng lương**, khoảng chấp nhận được có thể được định nghĩa:

- Dựa trên **lương thấp nhất và lương cao nhất** trong tập dữ liệu huấn luyện.

- Hoặc theo một **khoảng xác định trước** dựa trên miền giá trị thực tế của biến mục tiêu.

RAM giúp cung cấp một **cái nhìn trực quan và thực tiễn hơn về hiệu suất dự đoán**, đặc biệt hữu ích khi người dùng quan tâm đến việc dự đoán có nằm trong khoảng hợp lý thay vì đạt độ chính xác tuyệt đối.

Công thức tính RAM được định nghĩa như sau:

$$RAM = \frac{1}{n} \sum_{i=1}^n I(y_i \in [y_{min}, y_{max}]) \quad (1 \leq i \leq n)$$

Trong đó:

- là tổng số lượng mẫu trong tập dữ liệu đánh giá.
- là giá trị dự đoán của mô hình hồi quy cho mẫu thứ i .
- là giá trị thấp nhất của biến mục tiêu (lương) trong tập dữ liệu huấn luyện hoặc ngưỡng dưới của khoảng chấp nhận.
- y_{max} là giá trị cao nhất của biến mục tiêu (lương) trong tập dữ liệu huấn luyện hoặc ngưỡng trên của khoảng chấp nhận.
- là hàm chỉ thị, trả về 1 nếu điều kiện bên trong là đúng, và 0 nếu sai.

Theo đó, RAM sẽ trả về:

- **1**: Nếu kết quả hồi quy () nằm trong khoảng từ lương thấp nhất (y_{min}) đến lương cao nhất (y_{max}).
- **0**: Nếu kết quả hồi quy () nằm ngoài khoảng đó.

5.3 Thông số chi tiết các thuật toán

5.3.1 RandomForestRegressor

- Phương pháp này xây dựng nhiều cây quyết định trong quá trình huấn luyện và đưa ra dự đoán trung bình của các cây riêng lẻ. Các tham số chính là:

Các tham số được thiết lập tường minh:

- `n_estimators`: 100 - Số lượng cây quyết định được xây dựng trong rừng.
- `max_depth`: 12 - Độ sâu tối đa của mỗi cây.
- `min_samples_split`: 3 - Số lượng mẫu tối thiểu cần có để phân tách một nút.
- `min_samples_leaf`: 4 - Số lượng mẫu tối thiểu tại nút lá.
- `max_features`: 0.7 - Tỷ lệ đặc trưng được chọn ngẫu nhiên khi tìm kiếm điểm phân tách tốt nhất.
- `bootstrap`: True - Sử dụng bootstrap sampling để tạo tập con cho từng cây.
- `min_impurity_decrease`: 0.0 - Ngưỡng giảm độ tinh khiết tối thiểu để thực hiện phân tách.
- `random_state`: 42 - Hạt giống ngẫu nhiên để đảm bảo tính tái lập.

5.3.2 LGBMRegressor

Các tham số được thiết lập tường minh:

- `n_estimators`: 200 - Số lượng cây tối đa.
- `learning_rate`: 0.1 - Tốc độ học của mô hình.
- `num_leaves`: 63 - Số lá tối đa trong một cây.
- `max_depth`: 6 - Độ sâu tối đa của cây.
- `min_child_samples`: 50 - Số mẫu tối thiểu cần có ở nút lá.
- `subsample`: 0.8 - Tỷ lệ mẫu được chọn ngẫu nhiên để huấn luyện mỗi cây.
- `colsample_bytree`: 0.7 - Tỷ lệ đặc trưng được chọn ngẫu nhiên cho mỗi cây.

- `reg_alpha`: 0.3 - Tham số điều chuẩn L1.
- `reg_lambda`: 0.3 - Tham số điều chuẩn L2.
- `objective`: 'regression' - Bài toán hồi quy.
- `metric`: 'mae' - Thước đo đánh giá trong quá trình huấn luyện.
- `boosting_type`: 'gbdt' - Phương pháp tăng cường độ dốc truyền thống.
- `random_state`: 42 - Hạt giống ngẫu nhiên để đảm bảo tính tái lập.

5.3.3 CatBoostRegressor

Các tham số được thiết lập tường minh:

- `iterations`: 800 - Số vòng lặp tối đa.
- `learning_rate`: 0.05 - Tốc độ học.
- `depth`: 6 - Độ sâu tối đa của cây.
- `l2_leaf_reg`: 5 - Tham số điều chuẩn L2.
- `eval_metric`: 'MAE' - Thước đo đánh giá hiệu suất.
- `subsample`: 0.7 - Tỷ lệ mẫu ngẫu nhiên được chọn để huấn luyện mỗi cây.
- `bagging_temperature`: 5 - Điều chỉnh mức độ ngẫu nhiên trong bagging.
- `border_count`: 200 - Số lượng biên (borders) khi phân rời rạc các đặc trưng liên tục.
- `random_strength`: 5 - Độ mạnh của ngẫu nhiên hóa trong split.
- `verbose`: 0 - Tắt hiển thị chi tiết trong quá trình huấn luyện.
- `random_state`: 42 - Hạt giống ngẫu nhiên đảm bảo tính tái lập.

5.4 Đánh giá thực nghiệm

5.4.1 Kết quả thực nghiệm

Model	RMSE	R2	RAM
-------	------	----	-----

Random Forest	28.87	0.35	60%
LightGBM	28.92	0.35	60.0%
CatBoost	28.64	0.36	60%

Hình 5.1: Kết quả thực nghiệm

5.4.2 Nhận xét

5.4.2.1 Đánh giá tổng quan

Nhìn chung, các mô hình hồi quy được thử nghiệm (Random Forest, LightGBM, CatBoost) đều cho thấy hiệu suất tương đối ổn định. Cụ thể:

- RMSE của các mô hình dao động từ 28.64 đến 28.92, cho thấy mức sai số trung bình của dự đoán tương đối thấp và gần nhau giữa các mô hình.
- R^2 đạt khoảng 0.35–0.36, phản ánh rằng các mô hình giải thích được khoảng 35–36% sự biến thiên của biến mục tiêu. Điều này cho thấy khả năng dự đoán ở mức vừa phải, vẫn còn một phần lớn phương sai của biến phụ thuộc chưa được giải thích.
- RAM (Range Accuracy Metric) đạt xấp xỉ 60% cho tất cả các mô hình, chứng tỏ rằng tỷ lệ dự đoán nằm trong khoảng lương thực tế là tương đối tốt, nhưng vẫn có dư địa cải thiện.

Như vậy, mặc dù các mô hình có sự khác biệt nhỏ về RMSE và R^2 , nhưng tất cả đều duy trì khả năng dự đoán ổn định và giữ các giá trị dự đoán trong khoảng chấp nhận được, phù hợp cho các ứng dụng ước lượng lương với mức chính xác tương đối.

5.4.2.2 Đánh giá theo từng độ đo

RMSE (Root Mean Squared Error):

- Giá trị RMSE thấp nhất thuộc về CatBoost (28.64), cho thấy mô hình này có sai số dự đoán trung bình nhỏ nhất.
- Random Forest (28.87) và LightGBM (28.92) cũng cho hiệu suất RMSE tốt, chênh lệch rất nhỏ so với CatBoost.
- Sự khác biệt về RMSE giữa ba mô hình chỉ khoảng 0.28 đơn vị, gợi ý rằng tất cả các mô hình đều duy trì mức sai số tương đối gần nhau, không có mô hình nào vượt trội hoàn toàn về sai số tuyệt đối.

R² (Hệ số xác định):

- CatBoost tiếp tục dẫn đầu với $R^2 = 0.36$, phản ánh khả năng giải thích khoảng 36% phương sai của biến mục tiêu.
- Random Forest (0.35) và LightGBM (0.35) có R^2 tương tự nhau, cho thấy mức độ giải thích biến phụ thuộc gần như đồng nhất giữa các mô hình này.
- Mặc dù R^2 không cao, nhưng vẫn đủ để mô hình cung cấp dự đoán có ý nghĩa, đặc biệt trong các ứng dụng định lượng mang tính tham khảo.

RAM (Range Accuracy Metric):

- Tất cả các mô hình đều đạt RAM ~60%, chứng tỏ tỷ lệ dự đoán nằm trong khoảng lương thực tế là tương đối tốt.
- Sự gần bằng về RAM giữa các mô hình cho thấy cả ba mô hình đều giữ được khả năng dự đoán trong phạm vi hợp lý, điều này hữu ích trong các ứng dụng mà việc giữ dự đoán trong khoảng chấp nhận được quan trọng hơn so với độ chính xác tuyệt đối.

5.4.2.3 Phân tích nguyên nhân

Nguyên nhân các độ đo hồi quy thấp (RMSE và

R^2):

- Thiếu thông tin trong dữ liệu: Các biến độc lập hiện có có thể chưa đủ mạnh để giải thích biến mục tiêu. Một số yếu tố quan trọng ảnh hưởng đến lương có thể chưa được thu thập hoặc chưa được đưa vào dữ liệu.
- Mối quan hệ phi tuyến phức tạp: Mặc dù đã sử dụng các mô hình phi tuyến như Rừng ngẫu nhiên, Cây quyết định và các mô hình Boosting, giá trị R^2 vẫn còn thấp. Điều này cho thấy mối quan hệ giữa các biến độc lập và biến mục tiêu rất phức tạp, có khả năng phi tuyến cao, và các mô hình hiện tại chưa nắm bắt được toàn bộ.
- Nhiễu trong dữ liệu: Dữ liệu có thể chứa nhiều nhiễu hoặc các ngoại lai (outliers) ảnh hưởng đến khả năng học và dự đoán của mô hình.

Nguyên nhân RAM ổn định (Range Accuracy Metric):

- Phạm vi biến mục tiêu ổn định: Biến mục tiêu (lương) có thể có phân phối tập trung hoặc phạm vi giá trị tương đối ổn định, giúp các dự đoán dễ rơi vào khoảng chấp nhận được.
- Bias của mô hình: Các mô hình có xu hướng dự đoán về giá trị trung bình hoặc trong một khoảng hẹp. Điều này làm tăng tỷ lệ RAM nhưng không đồng nghĩa với việc dự đoán từng giá trị cụ thể chính xác.

5.4.2.4 Phương pháp Cải thiện

Kỹ thuật Feature Engineering và Lựa chọn đặc trưng:

- Tạo thêm đặc trưng mới:

Các đặc trưng bổ sung được sinh ra từ dữ liệu hiện có, giúp phân tích sâu hơn các yếu tố quan trọng trong Job Description (JD). Ví dụ, trích xuất kỹ năng, kinh

nghiệm, mức học vấn, vị trí chức vụ,... từ JD để tạo các biến số định lượng hoặc phân loại mới.

- Lựa chọn đặc trưng (Feature Selection):

Sử dụng các phương pháp lựa chọn đặc trưng nhằm xác định và giữ lại những đặc trưng có ảnh hưởng mạnh nhất đến biến mục tiêu (lương), đồng thời loại bỏ các đặc trưng gây nhiễu. Điều này giúp giảm độ phức tạp của mô hình, tăng hiệu suất dự đoán và tránh overfitting.

- Phân bố dự đoán theo thuộc tính quan trọng:

Kiểm soát mức độ biến thiên của dữ liệu về lương bằng cách phân tích và đánh giá dự đoán theo các nhóm thuộc tính quan trọng như khu vực, chức vụ, cấp bậc hay loại hình công việc. Phân bố này giúp hiểu rõ hơn khả năng dự đoán trong các phân khúc cụ thể.

- Điều chỉnh siêu tham số (Hyperparameter Tuning):

Áp dụng các kỹ thuật tối ưu hóa chuyên sâu như Grid Search, Random Search, hoặc các phương pháp tiên tiến hơn như Bayesian Optimization để tìm bộ siêu tham số tối ưu cho từng mô hình. Việc này giúp mô hình đạt hiệu suất dự đoán tốt nhất trên tập dữ liệu huấn luyện và kiểm tra.

- Xử lý dữ liệu:

Chuẩn hóa, biến đổi hoặc biến đổi phi tuyến dữ liệu nhằm đảm bảo các giả định của mô hình được thỏa mãn, đồng thời nâng cao khả năng học của mô hình và cải thiện chất lượng dự đoán.

- Kỹ thuật Ensemble Learning:

Kết hợp nhiều mô hình khác nhau (ví dụ: Stacking, Bagging, Boosting) để tận dụng ưu điểm riêng của từng mô hình, giảm thiểu nhược điểm, đồng thời cải thiện độ chính xác và độ ổn định của dự đoán.

CHƯƠNG 6 :KẾT LUẬN

6.1 Tóm tắt đề tài

Đề tài "Hệ thống Dự đoán Lương và Nhu cầu Kỹ năng trên Thị trường Việc làm" tập trung giải quyết vấn đề thiếu minh bạch thông tin về lương và kỹ năng trong lĩnh vực dữ liệu, một thách thức quan trọng đối với cả người lao động và nhà tuyển dụng. Chúng tôi đã thu thập và hợp nhất bốn bộ dữ liệu từ Kaggle, bao gồm Data Analyst, Data Scientist, Data Engineer , Business Analyst và Other, tạo ra một bộ dữ liệu tổng hợp với khoảng 14,161 bản ghi.

Quá trình Khai phá Dữ liệu (EDA) được thực hiện nhằm hiểu rõ hơn về đặc điểm dữ liệu, phân phối lương, các vị trí phổ biến, cũng như mối quan hệ giữa các yếu tố như xếp hạng công ty, địa điểm và ngành nghề với mức lương. Một bước đột phá trong giai đoạn tiền xử lý là việc áp dụng mô hình ngôn ngữ lớn (LLM - Google Gemini) để trích xuất các thông tin có cấu trúc như kỹ năng, kinh nghiệm và học vấn từ mô tả công việc (JD), thay thế cho phương pháp TF-IDF truyền thống vốn còn nhiều hạn chế. Các thông tin này sau đó được chuẩn hóa và mã hóa để đưa vào mô hình học máy.

- Ba mô hình học máy chính đã được xây dựng và đánh giá, bao gồm Random Forest, LightGBM và CatBoost. Kết quả thực nghiệm cho thấy:
- CatBoost đạt RMSE thấp nhất (28.64), R2 cao nhất (0.36) và RAM 60%, thể hiện sai số dự đoán trung bình tối ưu và khả năng giải thích biến động của biến phụ thuộc tốt nhất trong các mô hình thử nghiệm.
- Random Forest có RMSE = 28.87, R2 = 0.35 và RAM = 60%, thể hiện hiệu suất gần tương đương với CatBoost.

LightGBM có RMSE = 28.92, R2 = 0.35 và RAM = 60%, cũng đạt hiệu quả ổn định nhưng hơi thấp hơn CatBoost về RMSE.

Các giá trị RAM cao (60%) cho thấy tất cả các mô hình có khả năng dự đoán nằm trong khoảng giá trị thực tế của biến mục tiêu, điều này hữu ích trong các ứng dụng thực tiễn, nơi việc giữ dự đoán trong phạm vi hợp lý quan trọng hơn là độ chính xác tuyệt đối. Mặc dù R2 chưa cao, kết quả cho thấy các mô hình đã nắm bắt được một phần đáng kể phương sai của biến mục tiêu và mở ra nhiều hướng cải thiện trong việc nâng cao hiệu suất dự đoán thông qua Feature Engineering, lựa chọn đặc trưng, điều chỉnh siêu tham số và kỹ thuật Ensemble Learning.

6.2 Đóng góp của đề tài

Đề tài đã mang lại những đóng góp đáng chú ý sau:

- **Xây dựng bộ dữ liệu tổng hợp:** Hợp nhất thành công bốn bộ dữ liệu lớn từ Kaggle (Data Analyst, Data Scientist, Data Engineer, Business Analyst), tạo ra một nguồn tài nguyên phong phú và toàn diện cho việc phân tích thị trường lao động trong lĩnh vực dữ liệu, với khoảng 14,161 bản ghi.
- **Ứng dụng LLM tiên tiến trong tiền xử lý:** Sử dụng Google Gemini API để trích xuất thông tin cấu trúc từ mô tả công việc (JD), một hướng tiếp cận mới và hiệu quả, giúp tạo ra các đặc trưng chất lượng cao, có ý nghĩa hơn so với các phương pháp NLP truyền thống (ví dụ TF-IDF).
- **So sánh và đánh giá đa dạng mô hình:** Thực hiện đánh giá chi tiết ba mô hình hồi quy chính (Random Forest, LightGBM, CatBoost) về RMSE, R2 và RAM. Kết quả cho thấy CatBoost đạt RMSE thấp nhất (28.64), R2 cao nhất (0.36) và RAM 60%, trong khi Random Forest và LightGBM cũng duy trì hiệu suất ổn định, chứng minh khả năng dự đoán tốt và giữ dự đoán trong khoảng giá trị thực tế của biến mục tiêu.
- **Đề xuất độ đo RAM:** Giới thiệu Độ đo Chính xác Khoảng (Range Accuracy Metric – RAM), một phương pháp đánh giá bổ sung giúp đo lường tính thực tiễn

và độ tin cậy của dự đoán hồi quy, đặc biệt hữu ích trong các ứng dụng mà việc dự đoán nằm trong phạm vi hợp lý quan trọng hơn là sai số tuyệt đối.

CHƯƠNG 7 :HƯỚNG PHÁT TRIỂN ĐỀ TÀI

Dựa trên những kết quả đã đạt được và các hạn chế hiện tại, chúng tôi đề xuất một số hướng phát triển tiềm năng cho đề tài trong tương lai:

Nâng cao khai thác đặc trưng từ dữ liệu JD:

- Trích xuất thông tin chi tiết hơn: Mở rộng việc sử dụng LLM để khai thác sâu các thông tin khác từ mô tả công việc (JD) như phúc lợi, văn hóa công ty, mức độ cấp bậc (seniority), trách nhiệm chính và các yêu cầu mềm.
- Tự động gán nhãn bằng LLM với kiểm duyệt thủ công: Xây dựng quy trình tự động gán nhãn (kỹ năng, kinh nghiệm, học vấn, ...) cho một lượng lớn JD bằng LLM, kết hợp kiểm duyệt thủ công một phần để đảm bảo chất lượng, phục vụ cho việc tạo bộ dữ liệu huấn luyện lớn hơn và tinh chỉnh (fine-tuning) các mô hình NLP chuyên biệt.
- Phân tích xu hướng theo thời gian: Nếu dữ liệu được thu thập theo dòng thời gian, thực hiện phân tích sự thay đổi về nhu cầu kỹ năng, mức lương, và các yêu cầu công việc theo từng giai đoạn để dự báo xu hướng thị trường lao động.

Cải tiến mô hình học máy:

- Tinh chỉnh siêu tham số nâng cao: Áp dụng các kỹ thuật tối ưu hóa siêu tham số như Bayesian Optimization, Optuna để tìm bộ tham số tốt nhất cho các mô hình, đặc biệt là LightGBM, nhằm cải thiện RMSE, R2 và RAM.
- Xây dựng mô hình Ensemble phức tạp: Triển khai các kỹ thuật Stacking hoặc Blending, kết hợp dự đoán từ nhiều mô hình mạnh nhất (ví dụ: XGBoost,

CatBoost, LightGBM, hoặc TabNet) để tạo mô hình tổng hợp với hiệu suất dự đoán cao hơn.

Triển khai thực tế và ứng dụng:

- Xây dựng API phân loại công việc: Phát triển API cho phép người dùng hoặc hệ thống khác gửi JD (dạng văn bản hoặc URL) và nhận dự đoán lương, phân loại công việc, cùng danh sách kỹ năng chính được trích xuất.
- Hệ thống cập nhật Real-time: Xây dựng hệ thống tự động thu thập (crawl) và cập nhật thông tin việc làm từ các trang tuyển dụng lớn (LinkedIn, TopCV, VietnamWorks), xử lý, phân tích và hiển thị kết quả trên dashboard tương tác.
- Giao diện người dùng thân thiện: Phát triển website hoặc ứng dụng di động, cho phép người tìm việc nhập hồ sơ/kỹ năng để nhận dự đoán lương, gợi ý kỹ năng cần phát triển, hoặc đánh giá vị trí phù hợp trên thị trường lao động.
- gợi ý việc làm và lương phù hợp, và cho phép nhà tuyển dụng đăng tin, tìm kiếm ứng viên, và tham khảo mức lương thị trường.

TÀI LIỆU THAM KHẢO

- [1] Alsheyab, A. R., Alkhasawneh, M., & Shahin, N. (2025). Job market cheat codes: Prototyping salary prediction and job grouping with synthetic job listings. *arXiv preprint arXiv:2506.15879*. <https://arxiv.org/abs/2506.15879>
- [2] Aminu, H., Yau, B. I., Zambuk, F. U., Nanin, E. R., Abdullahi, A., & Yakubu, I. Z. (2023). Salary prediction model using principal component analysis and deep neural network algorithm. *International Journal of Innovative Science and Research Technology*, 8(12). <https://doi.org/10.5281/zenodo.10629245>
- [3] Andrew MVD. (2021). *Business analyst jobs dataset*. Kaggle. <https://www.kaggle.com/datasets/andrewmvd/business-analyst-jobs>
- [4] Andrew MVD. (2021). *Data analyst jobs dataset*. Kaggle. <https://www.kaggle.com/datasets/andrewmvd/data-analyst-jobs>
- [5] Andrew MVD. (2021). *Data engineer jobs dataset*. Kaggle. <https://www.kaggle.com/datasets/andrewmvd/data-engineer-jobs>
- [6] Andrew MVD. (2021). *Data scientist jobs dataset*. Kaggle. <https://www.kaggle.com/datasets/andrewmvd/data-scientist-jobs>
- [7] Arik, S. O., & Pfister, T. (2021). TabNet: Attentive interpretable tabular learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(8), 6679–6687. <https://doi.org/10.1609/aaai.v35i8.16826>
- [8] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. <https://doi.org/10.1145/2939672.2939785>
- [9] Deshpande, P. M., & Shinde, S. K. (2023). Salary prediction using ensemble learning models. *[Conference/Journal details]*. [Thông tin xuất bản chưa đầy đủ]

- [10] Google. (n.d.). *Gemini API documentation*. <https://ai.google.dev/docs>
- [11] Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., ... & Oliphant, T. E. (2020). Array programming with NumPy. *Nature*, 585(7825), 357–362. <https://doi.org/10.1038/s41586-020-2649-2>
- [12] Ji, Y., Sun, Y., & Zhu, H. (2025). Enhancing job salary prediction with disentangled composition effect modeling: A neural prototyping approach. *arXiv preprint arXiv:2503.12978*. <https://arxiv.org/abs/2503.12978>
- [13] Jiang, W. (2024). The investigation and prediction for salary trends in the data science industry. *Applied and Computational Engineering*, 50, 8–14. <https://doi.org/10.54254/2755-2721/50/20241102>
- [14] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., ... & Liu, T. Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30. <https://papers.nips.cc/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html>
- [15] Matbouli, Y. T., & Alghamdi, S. M. (2022). Statistical machine learning regression models for salary prediction featuring economy-wide activities and occupations. *Information*, 13(10), 495. <https://doi.org/10.3390/info13100495>
- [16] McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 445, 51–56. <https://doi.org/10.25080/Majora-92bf1922-00a>
- [17] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O.,& Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. <http://jmlr.org/papers/v12/pedregosa11a.html>
- [18] Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing*

Systems, 31. <https://papers.nips.cc/paper/2018/hash/14491b756b3a51daac41c24863285549-Abstract.html>